

Kapitel 3

Psychologische Forschung und Methodenlehre




Abbildung 3.1: Welche Methoden werden eingesetzt, um psychologische Phänomene zu untersuchen und wie läuft der psychologische Forschungsprozess ab?

In diesem Kapitel werden Themen rund um die Psychologische Forschung und Methodenlehre behandelt. Nach einem Überblick, inwiefern sich die wissenschaftliche Psychologie von der Alltagspsychologie unterscheidet und welche Rolle dabei der Methodenlehre zukommt (Kapitel 3.1), werden verschiedene Bausteine des psychologischen Forschungsprozesses beleuchtet. Dazu zählt die Entwicklung von Fragestellungen (Kapitel 3.2), die Versuchsplanung (Kapitel 3.3) die experimentelle Methode (Kapitel 3.4) und die deskriptive Statistik (Kapitel 3.5).

3.1 Einführung: Was ist die Methodenlehre?

3.1.1 Alltagspsychologie vs. wissenschaftliche Psychologie

Die Psychologie ist eine Wissenschaft mit viel Alltagsbezug. Menschen haben Vorstellungen über das eigene Erleben und Verhalten sowie auch über das Erleben und Verhalten anderer Personen, da jede Person im Alltag bereits Erfahrungen gesammelt und daraus vermeintliche Gesetzmäßigkeiten abgeleitet hat. Durch Erfahrungen werden Alltagstheorien über die Ursachen und die Konsequenzen des Verhaltens anderer Personen gebildet. Man bezeichnet diese Art von Psychologie als **Alltagspsychologie** oder auch Laienpsychologie. Davon abzugrenzen ist die wissenschaftliche Psychologie. Die **wissenschaftliche Psychologie** überprüft solche Theorien mit wissenschaftlichen Methoden und hat zum Ziel, fundierte, prüfbare Aussagen über den Wahrheitsgehalt von Alltagsphänomenen zu treffen. Tatsächlich widerspricht die wissenschaftliche Psychologie oftmals den durch den „gesunden“ Menschenverstand gebildeten „Lebensweisheiten“.

Dass der gesunde Menschenverstand oft falsch liegt, ist darauf zurückzuführen, dass wir im Alltag selten hinterfragen, *wie* wir die Welt wahrnehmen und Informationen verarbeiten. Es werden **Heuristiken** (siehe Infobox 3.1) eingesetzt, die es ermöglichen, Informationen schnell zu identifizieren und darauf aufbauend Entscheidungen zu treffen. Die dabei angewandten Strategien sind jedoch nicht fehlerfrei und unterliegen bestimmten **kognitiven Verzerrungen**. Darunter versteht man allgemein systematische fehlerhafte Tendenzen beim Wahrnehmen, Erinnern, Denken und Urteilen (Wirtz, 2023).

Infobox 3.1: Heuristik

Unter Heuristiken versteht man Methoden, die es ermöglichen, mit unvollständigen Informationen und wenig Zeit zu urteilen und Entscheidungen zu treffen. Heuristiken werden auch als Faustregeln bezeichnet, die schnelle Lösungen liefern und die Urteilsfindung erleichtern. In vielen Fällen führen Heuristiken zu korrekten Urteilen, aufgrund der „sparsamen“ Art sind sie jedoch fehleranfällig. Ein Beispiel für eine Heuristik ist die Repräsentativitätsheuristik, der die implizite Annahme zugrunde liegt, dass Ereignisse, die typischer für etwas sind, auch wahrscheinlicher sind (Gerrig et al., 2018). Angenommen, Sie werfen eine Münze mehrmals hintereinander, welche Reihenfolge an Münzwürfen (K = Kopf, Z = Zahl) ist wahrscheinlicher? K–K–K–K–K oder K–Z–Z–K–Z? Tatsächlich sind diese beiden Reihenfolgen gleich wahrscheinlich, da jedes der Ereignisse (jeder einzelne Münzwurf) eine Wahrscheinlichkeit von 50 % hat (Kopf oder Zahl) und vorangegangene Münzwürfe keinen Einfluss auf den aktuellen Münzwurf haben.

Ein Beispiel für eine kognitive Verzerrung ist der **Rückschaufehler** (engl. *Hindsight Bias*). Dieser bezeichnet den Umstand, dass Menschen im Nachhinein oft den Eindruck haben, sie hätten den Ausgang eines Geschehnisses schon vorher richtig voraussagen können (Sedlmeier & Renkewitz, 2013). Beispielsweise haben Personen nach einem Spiel häufig den subjektiven Eindruck, dass sie schon im Vorhinein gewusst hätten, wer gewinnen würde.

KAPITEL 3. PSYCHOLOGISCHE FORSCHUNG UND METHODENLEHRE

Ein anderes Beispiel ist der **Bestätigungsfehler** (engl. Confirmation Bias). Darunter versteht man die Neigung, jenen Informationen, welche die eigene Überzeugung bestätigen, mehr Bedeutung beizumessen als Informationen, die dieser Überzeugung widersprechen (Gazzaniga et al., 2017). Angenommen, Sie haben ein Lieblingsfußballteam, von dessen Leistung Sie überzeugt sind, und lesen einen Zeitungsartikel über dieses Team, in dem argumentiert wird, dass sich die sportliche Leistung des Teams in der diesjährigen Saison verschlechtert hat. Sie können das nicht glauben und sind der Überzeugung, dass die Person, die diesen Artikel geschrieben hat, keine Ahnung von Fußball hat. Sie begeben sich auf die Suche nach anderen Artikeln, in denen über die Leistung des Teams berichtet wurde, und nach kurzer Suche finden Sie auch einen, der zum Inhalt hat, dass das Team beim letzten Spiel gut gespielt hat, wodurch Sie sich in Ihrer Annahme bestätigt fühlen, dass der Artikel davor keine Aussagekraft hat. In diesem Szenario wäre der Bestätigungsfehler eingetreten und die Artikel wurden nicht objektiv, sondern mit einer bereits bestehenden Meinung, gelesen, welche darüber bestimmt hat, welcher Wahrheitsgehalt dem jeweiligen Artikel beigemessen wurde.

Vor dem Hintergrund, dass die wissenschaftliche Psychologie nach wissenschaftlicher Erkenntnis strebt, ist es wichtig, die Schwierigkeiten der alltäglichen Psychologie zu überwinden. Dazu müssen psychische Phänomene kritisch hinterfragt und auf deren Wahrheitsgehalt hin überprüft werden. Der erste Schritt in Richtung Wissenschaftlichkeit ist demnach das **kritische Denken**, worunter man das systematische Hinterfragen und die Bewertung von Informationen versteht (Sedlmeier & Renkewitz, 2013). Woher stammt die Information? Was genau ist gemeint? Liegt genug Evidenz für eine Behauptung vor?

Die Prüfung von psychologischen Phänomenen erfolgt anhand der **wissenschaftlichen Methode**. Das sind Vorgehensweisen, Verfahren und Techniken mit dem Ziel, Aussagen über die Welt zu treffen, die möglichst präzise und fehlerfrei sind (Sedlmeier & Renkewitz, 2013). Die **Methodenlehre** ist Grundlage jeder Wissenschaft und lehrt, welche wissenschaftlichen Methoden für ein gewisses Forschungsziel geeignet sind und wie diese Methoden anzuwenden sind. Durch das in der Methodenlehre vermittelte Vorgehen sollen Fehler, wie sie in der Alltagspsychologie auftreten, minimiert werden (Renner, Heydasch, & Ströhlein, 2012).

3.1.2 Was gilt als wissenschaftlich?

Döring (2023) beschreibt vier Standards der Wissenschaftlichkeit. Sind diese vier Standards erfüllt, kann eine Untersuchung als wissenschaftlich eingeordnet werden.

- Formulierung eines **wissenschaftlichen Forschungsproblems**: Das für eine Untersuchung ausgewählte Thema und die dazugehörigen Forschungsfragen müssen empirisch untersuchbar und auf Basis des aktuellen wissenschaftlichen Forschungsstands theoretisch erklärbar sein.
- Realisierung eines **wissenschaftlichen Forschungsprozesses**: Der Forschungsprozess muss auf das Forschungsproblem zugeschnitten sein und

KAPITEL 3. PSYCHOLOGISCHE FORSCHUNG UND METHODENLEHRE

der Einsatz etablierter wissenschaftlicher Forschungsmethoden und Techniken des wissenschaftlichen Arbeitens in allen Phasen des Forschungsprozesses wird vorausgesetzt.

- Orientierung an der **Wissenschafts- und Forschungsethik**: Bei der Durchführung von Untersuchungen sind ethische Regeln einzuhalten. Wird fremdes geistiges Eigentum als das eigene ausgegeben, werden Daten manipuliert oder Untersuchungsteilnehmende geschädigt, verliert die Untersuchung den Charakter der Wissenschaftlichkeit.
- Vollständige schriftliche **Dokumentation des gesamten Forschungsprojekts**: Der Forschungsprozess muss für andere Personen nachvollziehbar und auch replizierbar (siehe Infobox 3.2) sein. Zu diesem Zwecke ist es notwendig, dass alle Phasen des Forschungsprozesses genau dokumentiert werden.

Infobox 3.2: Replikation

Bei einer Replikationsstudie wird versucht, die Befunde bereits durchgeführter Studien zu replizieren, d. h. zu wiederholen. **Direkte (exakte) Replikationsstudien** haben zum Ziel, die Originalstudie so detailliert wie möglich nachzustellen. Unterscheiden sich die Befunde der Replikationsstudie von denen der Originalstudie, kann nachgeforscht werden, wodurch die Unterschiede zustande kommen. Möglicherweise wurde die Replikationsstudie nicht detailgetreu durchgeführt, es könnte aber auch sein, dass es sich bei den früheren Befunden um Zufallsbefunde handelt. Bei **konzeptionellen Replikationsstudien** werden Aspekte der Originalstudie abgewandelt und systematisch variiert. Bei Wahrnehmungsexperimenten könnte beispielsweise die Dauer der Darbietung der Reize variiert werden, um zu untersuchen, wie lange der Reiz dargeboten werden muss, damit ein bestimmter Effekt auftritt. Mit konzeptionellen Replikationsstudien möchte man die Generalisierbarkeit bzw. Spezifität von Befunden bestimmen. Die Bedeutung von Replikationsstudien hat in den letzten Jahren aufgrund der sogenannten **Replikationskrise** zugenommen. Darunter versteht man den Umstand, dass viele wissenschaftliche Erkenntnisse der Psychologie, aber auch von anderen Wissenschaften, in Replikationsstudien nicht bestätigt werden können. Als Ursachen dafür werden u. a. Daten- und Ergebnisfälschungen sowie der nicht-fachgemäße Umgang mit wissenschaftlichen Methoden angenommen. Um diesem unerfreulichen Umstand entgegenzuwirken, versucht man zunehmend, den wissenschaftlichen Forschungsprozess so transparent wie möglich zu gestalten. Dazu gehören die detaillierte Dokumentation des Forschungsprozesses sowie auch die Veröffentlichung der Daten, anhand derer die Befunde erlangt wurden (Wirtz, 2022).

Den vier Standards der Wissenschaftlichkeit können Kriterien der wissenschaftlichen Qualität zugeordnet werden, welche dazu dienen, einzuschätzen, ob eine wissenschaftliche Studie von guter, durchschnittlicher oder eher mangelhafter Qualität ist. Eine Studie guter Qualität untersucht ein Forschungsproblem, das **inhaltlich relevant** ist. Das beinhaltet die Frage, in welchem Maße die Studie mit ihren Ergebnissen zum wissenschaftlichen Erkenntnisfortschritt und zur Lösung praktischer Probleme beiträgt. Eine Studie guter Qualität weist eine hohe **methodische Strenge** im wissenschaftlichen Forschungsprozess auf. Die angewandten

KAPITEL 3. PSYCHOLOGISCHE FORSCHUNG UND METHODENLEHRE

Methoden sollen für die Bearbeitung des konkreten Forschungsproblems geeignet sein und regelkonform umgesetzt werden. Eine Studie guter Qualität weist eine hohe **ethische Strenge** auf, worunter man das Ausmaß, mit dem die einzelnen Standards der Wissenschafts- und Forschungsethik erfüllt werden, versteht. Eine Studie guter Qualität weist auch **Präsentationsqualität** auf. Dies wird anhand der Strukturiertheit und Lesbarkeit der Studie und der Einhaltung der Standards der Berichterstattung beurteilt. Insgesamt ist eine unzureichende Erfüllung eines dieser Kriterien nicht automatisch mit einer Studie schlechter Qualität gleichzusetzen, vielmehr ergibt sich die Qualität einer Studie aus dem Zusammenspiel dieser verschiedenen Faktoren (Döring, 2023).

3.1.3 Der wissenschaftliche Forschungsprozess

Man kann allgemein zwischen quantitativer Forschung und qualitativer Forschung unterscheiden. **Quantitative Forschung** hat zum Ziel, psychologische Phänomene messbar und somit vergleichbar zu machen. Sie ist zur Zeit der in der Psychologie vorherrschende Ansatz. Dieses Kapitel orientiert sich in erster Linie am quantitativen Forschungsprozess. In der quantitativen Forschung ist man weniger an Einzelpersonen interessiert, sondern vielmehr an Gruppen von Personen. Durch die Untersuchung mehrerer Personen, die einer Gruppe angehören, kann ein für die Gruppe typischer (repräsentativer) Wert hinsichtlich des untersuchten Merkmals ermittelt werden. Neben der quantitativen Forschung gibt es auch die **qualitative Forschung**, bei welcher sinnverstehende und interpretative Aspekte im Vordergrund stehen. Ist man beispielsweise an der Zufriedenheit mit einem Theaterbesuch interessiert, könnte man den Personen, die das Theater besucht haben, eine Skala 1–10 (1 = sehr unzufrieden, 10 = sehr zufrieden) vorlegen, anhand derer sie beurteilen sollen, wie sehr ihnen der Theaterbesuch gefallen hat. Dieses Vorgehen entspricht dem quantitativen Prozess und es ist möglich, einen Mittelwert über alle so erhaltenen Beurteilungen zu bilden. Man könnte die Fragen aber auch offen formulieren und danach fragen, wie sie den Theaterbesuch erlebt haben. In diesem Fall wird ein qualitatives Vorgehen gewählt und man wird individuelle Antworten erhalten, welche die Beobachtungsrealitäten der befragten Personen abbilden. Ob qualitative oder quantitative Forschungsmethoden zum Einsatz kommen, hängt maßgeblich vom jeweiligen Forschungsparadigma sowie der konkreten Fragestellung ab (Hussy, Schreier, & Echterhoff, 2013).

Der übliche Ansatz innerhalb des quantitativen Forschungsparadigmas ist der **hypothesenprüfende Ansatz**: Es wird eine Hypothese aufgestellt und anschließend überprüft. Dieser Prozess kann nach Renner et al. (2012) in mehrere Schritte untergliedert werden:

1. Wahl einer Forschungsfragestellung
2. Theoretische Einbettung und Ableitung von Hypothesen
3. Operationalisierung und Untersuchungsplanung
4. Durchführung der Untersuchung und Datenerhebung
5. Datenaufbereitung und Datenanalyse

KAPITEL 3. PSYCHOLOGISCHE FORSCHUNG UND METHODENLEHRE

6. Interpretation und Diskussion
7. Publikation und/oder Präsentation

Am Beginn eines Forschungsprozesses steht die Frage, was eigentlich untersucht werden soll. Von Forschenden wird meist persönliches Interesse und Begeisterung für ein Forschungsthema als Grund dafür angegeben, warum sie sich in ihren Untersuchungen genau diesem Thema widmen. Der Prozess des Findens einer Forschungsfragestellung sowie die theoretische Einbettung und Ableitung der überprüfbaren Hypothesen wird in Kapitel 3.2 näher beleuchtet. Ist entschieden, was genau untersucht werden soll, geht es an die Planung der Untersuchung. Es muss festgelegt werden, wer oder was untersucht werden soll, wie die psychischen Phänomene sichtbar und messbar gemacht werden können – die Operationalisierung – und wie die Untersuchung konkret ablaufen soll. Das Thema der Operationalisierung und Untersuchungsplanung wird in Kapitel 3.3 behandelt. In Kapitel 3.4 wird außerdem eine spezielle Art von Untersuchung – das Experiment – beleuchtet. Danach folgt die Durchführung der Untersuchung und die Erhebung der Daten. Im Kapitel zur experimentellen Methode finden Sie auch Beispiele dafür, worauf bei der Durchführung der Untersuchung geachtet werden sollte. Wurde die Untersuchung erfolgreich durchgeführt, werden die erhobenen Daten zunächst aufbereitet und anschließend analysiert. Bei der Datenaufbereitung werden die Daten gesichtet, auf Plausibilität geprüft und für die eigentliche Analyse vorbereitet. Möglicherweise müssen Fragebogendaten digitalisiert werden oder bestimmte Ausschnitte einer Gehirnaktivitätsaufzeichnung gefiltert werden. Die Datenanalyse erfolgt mittels statistischer Verfahren und entsprechender Software. Methoden der deskriptiven Statistik werden in Kapitel 3.5 behandelt. Anschließend werden die Ergebnisse der Datenanalyse interpretiert. Das bedeutet, dass Schlussfolgerungen aus den Daten gezogen und im Hinblick auf die Forschungsfrage gedeutet werden. Schließlich werden die Ergebnisse vorgestellt und/oder in einschlägigen Fachzeitschriften veröffentlicht. Dadurch wird sichergestellt, dass auch andere Personen und Forschende Zugang zu den neuen Erkenntnissen haben (Renner et al., 2012).

3.2 Theorien und Hypothesen

Der wissenschaftliche Forschungsprozess beginnt meist dann, wenn ein Phänomen beobachtet wird, welches die Frage aufwirft, warum dieses Phänomen aufgetreten ist, und zur Entwicklung einer Theorie zur Beantwortung dieser Frage führt. Eine **Theorie** ist eine geordnete Menge von Begriffen und Aussagen, die ein Phänomen oder eine Gruppe von Phänomenen zu erklären versucht. Sie besteht aus mehreren miteinander verbundenen Ideen und Konzepten und dient dazu, vergangene Beobachtungen zu erklären und zukünftige Beobachtungen vorherzusagen. Aus den Theorien lassen sich Hypothesen ableiten. **Hypothesen** sind konkrete und überprüfbare Vermutungen über einen Sachverhalt. Während Theorien eher breit und allgemein formuliert sind, beziehen sich Hypothesen auf einen konkreten Sachverhalt, der überprüfbar ist (Gazzaniga et al., 2017; Gerrig et al., 2018).

KAPITEL 3. PSYCHOLOGISCHE FORSCHUNG UND METHODENLEHRE

In diesem Lernskript werden zahlreiche Theorien behandelt, die sich mit unterschiedlichen psychologischen Phänomenen beschäftigen, wie beispielsweise die Theorie der kognitiven Entwicklung von Jean Piaget (siehe Kapitel 6.3.1). Piaget stellte die Theorie auf, dass die kognitive Entwicklung bei Kindern in vier verschiedene Entwicklungsstadien unterteilt werden kann. Diesen vier Entwicklungsstadien gab er Namen und legte Altersspannen fest, die den Entwicklungsstadien zugeordnet sind. Möchte man nun eine Untersuchung zu Piagets Theorie durchführen, kann nicht Piagets Theorie als Ganzes untersucht werden, da diese recht komplex ist. Es kann jedoch ein Bestandteil der Theorie, beispielsweise „Kinder unter zwei Jahren verfügen noch nicht über eine Objektpermanenz“, herausgenommen werden und daraus eine Hypothese abgeleitet werden, nämlich „Kinder zeigen auf ein zunächst für die Kinder sichtbares Objekt, das dann verdeckt wird, keine Reaktion mehr“. Diese Hypothese kann untersucht werden. Sind die resultierenden Ergebnisse derart, dass sie die Richtigkeit der Hypothese nahelegen, so kann die Theorie auf Grundlage neuer Hypothesen und Studien weiterentwickelt werden und beispielsweise die Frage aufgeworfen werden, warum die Kinder keine Reaktion mehr auf das Objekt zeigen. Sind die resultierenden Ergebnisse jedoch so, dass sie der Hypothese widersprechen, so erfährt die dahinterliegende Theorie keine Unterstützung und wird daher verworfen oder überarbeitet (siehe Abbildung 3.2).




Abbildung 3.2: Die Entwicklung von Theorien und die Ableitung sowie Überprüfung von Hypothesen stellt einen zyklischen Prozess dar, wodurch im Idealfall eine Theorie im Laufe der Zeit ständig weiterentwickelt wird und zu einem genaueren Erklärungsmodell eines Phänomens führt; in Anlehnung an Gazzaniga et al. (2017)

3.2.1 Anforderungen an wissenschaftliche Hypothesen

Hypothesen, die in wissenschaftlichen Studien untersucht werden, müssen eine Reihe von Merkmalen aufweisen, damit diese auch als wissenschaftliche Hypothesen bezeichnet werden können (Hussy et al., 2013):

- präzise und widerspruchsfreie Formulierung
- prinzipielle Widerlegbarkeit
- Operationalisierbarkeit
- Begründbarkeit

Hypothesen sollen **präzise und widerspruchsfrei formuliert** werden und keinen Raum für Interpretationen lassen. Ein Beispiel für eine Hypothese, die dieses Kriterium nicht erfüllt, wäre: „Kinder schlafen mehr“, weil hier offen bleibt, im Vergleich zu wem oder unter welchen Umständen Kinder mehr schlafen. Die Hypothese: „Durch ein spezifisches Hirntrauma ändert sich die sprachliche Leistung oder sie ändert sich nicht“, ist auch keine wissenschaftliche Hypothese, da hierbei das Kriterium der widerspruchsfreien Formulierung nicht gegeben ist. Hypothesen, die nicht widerspruchsfrei sind, sind auch nicht widerlegbar. Es gibt keine Möglichkeit, die oben genannte Aussage zu widerlegen, damit fällt auch das Kriterium der **prinzipiellen Widerlegbarkeit**. Ein weiteres Kriterium ist die **Operationalisierbarkeit**, auf die in Kapitel 3.3.1 näher eingegangen wird. Grob gesagt, versteht man darunter die Möglichkeit, dass die verwendeten (abstrakten) Begriffe einer Hypothese erfassbar und messbar sein müssen. Das Kriterium der **Begründbarkeit** bezieht sich darauf, dass der aktuelle Stand der Wissenschaft bei der Formulierung von wissenschaftlichen Hypothesen zu berücksichtigen ist – unter der Voraussetzung, dass bereits theoretische Modellannahmen oder empirische Befunde dazu existieren (Hussy et al., 2013). Außerdem müssen Hypothesen natürlich vor der Datensammlung aufgestellt werden und nicht wie in Abbildung 3.4.

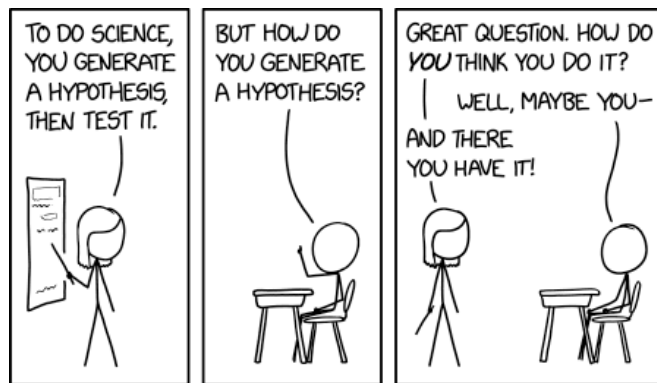


Abbildung 3.3: Hypothesen sind empirisch überprüfbare Vermutungen über einen Sachverhalt

3.2.2 Arten von Hypothesen

Bei näherer Betrachtung können verschiedene Arten von Hypothesen unterschieden werden. Je nach Art der Hypothese werden verschiedene statistische Verfahren eingesetzt, um die Hypothese zu überprüfen (Döring, 2023).

KAPITEL 3. PSYCHOLOGISCHE FORSCHUNG UND METHODENLEHRE




Abbildung 3.4: Die korrekte Reihenfolge: Zuerst die Hypothese formulieren und dann überprüfen; Abbildung aus Huber (2019, S. 61)

Unterschiedshypothesen: Unterschiedshypothesen sind Vermutungen über einen Unterschied zwischen zwei oder mehr Gruppen hinsichtlich einer Variable⁸. Eine Unterschiedshypothese kann entweder ungerichtet oder gerichtet sein. Bei einer ungerichteten Hypothese wird nur ein Unterschied zwischen Gruppen vermutet, wobei nicht näher spezifiziert wird, wie dieser Unterschied gerichtet ist. Ein Beispiel für eine **ungerichtete Unterschiedshypothese** wäre: „Linkshändigkeit tritt bei Männern und Frauen unterschiedlich häufig auf.“ Bei gerichteten Unterschiedshypothesen wird weiter spezifiziert inwiefern sich die Gruppen unterscheiden. Ein Beispiel für eine gerichtete Unterschiedshypothese wäre: „Linkshändigkeit tritt bei Männern häufiger auf als bei Frauen.“

Zusammenhangshypothesen: Zusammenhangshypothesen sind Vermutungen über den Zusammenhang zwischen zwei oder mehr Variablen. Man spricht auch davon, dass zwei Variablen **kovariieren** (siehe Infobox 3.3). Ein Beispiel für eine Zusammenhangshypothese wäre: „Die Anzahl der Stunden, die Eltern mit ihren Kindern lernen, kovariiert mit der durchschnittlichen Schulnote der Kinder.“ Innerhalb der Zusammenhangshypothesen kann weiters zwischen positiv gerichteten und negativ gerichteten Zusammenhangshypothesen unterschieden werden⁹. Eine **positiv gerichtete Zusammenhangshypothese** postuliert, dass hohe Werte einer Variable mit hohen Werten einer anderen Variable (und niedrige Werte einer Variable mit niedrigen Werten einer anderen Variable) assoziiert sind. Ein Beispiel für eine positiv gerichtete Zusammenhangshypothese wäre: „Je mehr Sport Personen treiben, desto mehr Punkte erreichen sie in einem Gedächtnistest.“ Eine **negativ gerichtete Zusammenhangshypothese** vermutet einen gegenläufigen Zusammenhang, bei der hohe Werte einer Variable mit niedrigen Werten der anderen Variable assoziiert sind. Ein Beispiel für eine negativ gerichtete Zusammenhangshypothese wäre: „Je mehr Sport Personen treiben, desto schlechter schneiden sie bei einem Gedächtnistest ab.“

Veränderungshypothesen: Veränderungshypothesen sind Vermutungen über die Veränderung von Variablen bei denselben Personen über die Zeit bzw. zwischen zwei Erhebungszeitpunkten. Auch bei Veränderungshypothesen kann zwischen ungerichteten und gerichteten Hypothesen unterschieden werden. Ein Beispiel für eine ungerichtete Veränderungshypothese wäre: „Durch eine spezielle psychotherapeutische Behandlung kommt es zu einer Veränderung der depressiven Symptomatik.“ Ein Beispiel für eine gerichtete Veränderungshypothese wäre: „Das Ausmaß der depressiven Symptomatik reduziert sich durch eine spezielle psychotherapeutische Behandlung.“ In Abgrenzung zu den Unterschiedshypothesen benötigen Veränderungshypothesen zur Überprüfung mehrere Erhebungszeitpunkte (Döring, 2023).

⁸Variablen repräsentieren in der psychologischen Forschung das operationalisierte Merkmal einer Person, wie beispielsweise die Körpergröße oder die Anzahl der Geschwister. In Kapitel 3.3.2 wird näher auf diesen Begriff eingegangen.

⁹Positiv und negativ ist hier nicht als eine Wertung zu verstehen, sondern beschreibt lediglich die Richtung des Zusammenhangs, zur Veranschaulichung siehe auch Abbildung 3.19.

Infobox 3.3: Kovariation und Kausalität

In psychologischen Untersuchungen wird häufig beobachtet, dass es einen Zusammenhang zwischen zwei Variablen gibt, wie beispielsweise zwischen der Lerndauer und der Schulnote. Kann in diesem Fall behauptet werden, dass die Lerndauer einen ursächlichen Einfluss auf die Schulnote hat? Nur bedingt! Eine solche Behauptung über die Kausalität wäre nur dann zulässig, wenn neben der Kovariation von Variable A und Variable B noch zwei weitere Voraussetzungen erfüllt sind: (1) A tritt zeitlich vor B auf und (2) andere Ursachen außer A können ausgeschlossen werden. In Kapitel 3.4 wird näher darauf eingegangen, wie in Untersuchungen jene Bedingungen hergestellt werden können, damit diese Voraussetzungen als erfüllt gelten können.

3.3 Operationalisierung und Untersuchungsplanung

In diesem Kapitel werden verschiedene Aspekte aufgegriffen, die bei der Planung einer Untersuchung bedacht werden müssen. Dazu zählt die Frage, wie psychische Phänomene beobachtbar und messbar gemacht werden können (Kapitel 3.3.1), verschiedene Arten von Variablen, deren Eigenschaften und Messung (Kapitel 3.3.2), worauf bei der Rekrutierung der Versuchspersonen und den resultierenden Stichproben geachtet werden muss (Kapitel 3.3.3) und weitere Aspekte, in denen sich verschiedene Untersuchungen voneinander unterscheiden können, wie beispielsweise der zeitliche Horizont oder der Ort der Untersuchung (Kapitel 3.3.4).

3.3.1 Was versteht man unter Operationalisierung?

Einen ersten Überblick davon, was Sie in diesem Kapitel erwartet und wie die einzelnen Begrifflichkeiten, die im Folgenden behandelt werden, miteinander in Beziehung stehen, soll Ihnen Abbildung 3.5 geben. Kehren Sie zu dieser Abbildung zurück, wenn die einzelnen Begriffe im Folgenden definiert werden.

Unter einem **Merkmal** versteht man in der psychologischen Forschung eine Eigenschaft, die zu einem Objekt oder einer Person gehört und unterschiedliche Merkmalsausprägungen aufweisen kann. Ein menschliches Individuum verfügt über eine Reihe an Merkmalen, welche auch dafür genutzt werden, dieses Individuum zu beschreiben. Das können sowohl äußerlich sichtbare Merkmale wie die Augenfarbe oder die Körpergröße sein, aber auch psychische Merkmale wie Intelligenz oder Gewissenhaftigkeit. Merkmale können sowohl zwischen Personen als auch innerhalb einer Person variieren, das bedeutet, dass ein Merkmal bei einer Person zu unterschiedlichen Zeitpunkten oder auch zwischen verschiedenen Personen verschiedene **Ausprägungen** annehmen kann. In diesem Zusammenhang kann zwischen qualitativen und quantitativen Merkmalen unterschieden werden. Bei **qualitativen Merkmalen** gibt es verschiedene Kategorien und eine Person kann anhand ihrer Merkmalsausprägung einer Kategorie zugeordnet werden. Beispiele für qualitative Merkmale sind die Nationalität oder auch die Augenfarbe einer Person. Bei **quantitativen Merkmalen** gibt es keine vordefinierten Kategorien, sondern es wird der Ausprägungsgrad auf einem Kontinuum beschrieben. Wenn

KAPITEL 3. PSYCHOLOGISCHE FORSCHUNG UND METHODENLEHRE




Abbildung 3.5: Was ist eine Messung, was versteht man unter Operationalisierung und wie stehen sich die Begriffe Merkmal und Variable gegenüber? (in Anlehnung an Leonhart, 2004)

diese Ausprägungen aus Zahlen bestehen, wie beispielsweise die Körpergröße in Zentimeter, spricht man auch von **Werten** (Hussy et al., 2013; Leonhart, 2004). Die Ausprägung des Merkmals Körpergröße hat bei Ihrer Geburt in der Regel einen Wert um die 50 Zentimeter angenommen und sich während Ihrer Kindheit über die Zeit stark verändert. Gleichmaßen weisen Ihre Bekannten mitunter andere Ausprägungen der Körpergröße auf als Sie.

Die Psychologie ist mit der Herausforderung konfrontiert, dass viele Merkmale nicht direkt beobachtet oder gemessen werden können. Während Verhalten zumindest teilweise beobachtbar und messbar ist, gestaltet sich dies beim Erleben deutlich schwieriger. Wie kann gemessen werden, was eine Person wahrnimmt, denkt oder fühlt? Was genau ist überhaupt gemeint, wenn wir von Intelligenz, Gedächtnis, Gewissenhaftigkeit, Depression oder Ärger sprechen?

Während man auf subjektiver Ebene ein mehr oder weniger gutes Verständnis über diese psychologischen Merkmale haben kann, ist eine objektive Definition dieser Merkmale nicht so einfach, wie es auf den ersten Blick möglicherweise scheint. Vielleicht haben Sie schon einmal den Ausdruck „Intelligenz ist das, was der Intelligenztest misst“ gehört. Unterschiedliche Intelligenztests liefern mitunter unterschiedliche Ergebnisse im Hinblick auf die Ausprägung der Intelligenz – abhängig davon, welches Verständnis über das dahinterliegende Merkmal (Intelligenz) in die Entwicklung des Intelligenztests eingeflossen ist. Gleiches trifft auf andere psychische Merkmale wie Gedächtnisleistung, Ängstlichkeit oder Gewissenhaftigkeit zu. Die Art und Weise wie ein Merkmal erhoben wird und das Verständnis von diesem Merkmal bedingen sich gewissermaßen gegenseitig (Sedlmeier & Renkewitz, 2013).

Da in der Psychologie sehr viele Merkmale nicht direkt beobachtbar sind, ist es notwendig, Indikatoren festzulegen, deren Beobachtung einen Rückschluss auf die dahinterliegenden Merkmale erlaubt. In diesem Zusammenhang kann man zwi-

KAPITEL 3. PSYCHOLOGISCHE FORSCHUNG UND METHODENLEHRE

schen manifesten und latenten Merkmalen unterscheiden. **Latente Merkmale** sind Merkmale, die nicht direkt beobachtet und gemessen werden können. Stattdessen wird auf **manifeste Merkmale** zurückgegriffen, die direkt beobachtet und gemessen werden können und den Anspruch haben, Indikatoren für das latente Merkmal zu sein. In der Folge schließt man von der Ausprägung des manifesten Merkmals auf die Ausprägung des latenten Merkmals. Die Festlegung der Menge an Operationen zur Erfassung eines Merkmals wird als **Operationalisierung** bezeichnet. Bei manifesten Variablen umfasst dies die Wahl des Messinstruments (z. B. ein Maßband zur Ermittlung der Körpergröße), bei latenten Merkmalen schließt dies auch die Auswahl von geeigneten beobachtbaren Indikatoren ein. Das operationalisierte Merkmal wird als **Variable** bezeichnet (Renner et al., 2012; Leonhart, 2004).

Angenommen, jemand interessiert sich für das Stresserleben von Personen beim Ausführen einer bestimmten Tätigkeit. Dann stellt Stress das latente Merkmal dar, welches nicht direkt erhoben werden kann. Es gibt jedoch Indikatoren, welche Rückschlüsse auf das Stresserleben ermöglichen. Neben der Möglichkeit, die Person direkt nach ihrem subjektiven Stresserleben zu fragen, könnte man auch körperliche Reaktionen, von denen bekannt ist, dass sie mit Stress in Verbindung stehen, messen. Diese messbaren Größen stellen manifeste Merkmale dar. Der Vorgang festzulegen, wie genau das Stresserleben erfasst werden soll, ist die Operationalisierung. Dazu gehört demnach nicht nur die Auswahl von Indikatoren, sondern auch wie diese Indikatoren erhoben werden sollen – die Wahl der **Messinstrumente** und der Messart. Fällt die Wahl des manifesten Merkmals auf das subjektive Stressempfinden und die Wahl des Messinstruments auf eine Skala von 0 = kein Stress bis 10 = maximaler Stress, dann entspricht das dadurch erhobene subjektive Stressempfinden dem operationalisierten Merkmal Stressempfinden und stellt die Variable in der Untersuchung dar.

3.3.2 Messung von Variablen und deren Eigenschaften

Ein Begriff, der in diesem Kapitel schon häufiger vorgekommen und zentrales Element der (psychologischen) Forschung ist, ist die Messung. Eine **Messung** ist allgemein die Zuordnung von Zahlen zu Merkmalsausprägungen von Objekten, wobei diese Zuordnung einer Zuordnungsregel folgen muss, welche gewährleistet, dass bestimmte Beziehungen zwischen den Ausprägungen des Merkmals in der Messung abgebildet werden (Sedlmeier & Renkewitz, 2013). Ist beispielsweise eine Person größer als eine andere, so sollte ersterer im Rahmen der Messung auch eine höhere Zahl zugeordnet werden. Zwei Personen mit unterschiedlichen Augenfarben sollten im Rahmen der Messung verschiedene Zahlen zugeordnet werden, wohingegen Personen mit gleichen Augenfarben die gleichen Zahlen zugeordnet werden sollen. Die gewonnenen Messungen werden auch als **Daten** bezeichnet (siehe auch Tabelle 3.1).

Die Messung erfolgt mit **Messinstrumenten**. Die Wahl eines angemessenen Messinstruments zur Messung von Merkmalsausprägungen ist Teil der Operationalisierung. Bei manchen, vor allem äußerlich sichtbaren, Merkmalen ist die Wahl

KAPITEL 3. PSYCHOLOGISCHE FORSCHUNG UND METHODENLEHRE

Tabelle 3.1: Beispieldaten: Durch die Messung werden anhand von Zuordnungsregeln Zahlen zu Merkmalsausprägungen zugeordnet

id	im Sportverein	Nationalität	höchster Bildungsabschluss	Körpergröße in cm
1	0	2	3	168
2	1	1	2	180
3	1	2	4	156
4	0	3	2	171
5	0	1	1	182

Sportverein 0 = nein 1 = ja	Nationalität 1 = Österreich 2 = Deutschland 3 = Schweiz 4 = Italien	Höchster Bildungsabschluss 0 = kein Abschluss 1 = Pflichtschule 2 = Matura 3 = Bachelorstudium 4 = Masterstudium
--	--	--

des Messinstruments eindeutig. Für die Messung der Körpergröße ist ein Maßband angemessen und für die Messung des Körpergewichts wird eine Waage verwendet. Bei anderen Merkmalen gestaltet sich die Auswahl eines geeigneten Messinstruments deutlich schwieriger. Messinstrumente, die in der Psychologie gebräuchlich sind, sind beispielsweise Fragebögen, psychologische Tests (siehe Kapitel 8.3) und Apparaturen, über die Vorgänge im Körper, wie Puls, Gehirnaktivität und Hormonspiegel, gemessen werden können. Über einen Fragebogen, der Fragen zu verschiedenen Aspekten der Angst beinhaltet, kann eine Messung der aktuellen Angstausprägung oder (je nach Art des Fragebogens) der generellen Ängstlichkeit erfolgen. Psychologische Tests haben den Anspruch, Ausprägungen latenter Merkmale zu erfassen, indem Aufgaben bearbeitet werden, die den Einsatz dieser Merkmale erfordern (Döring, 2023). So gibt es beispielsweise psychologische Tests, die die Kapazität des Kurzzeitgedächtnisses messen, indem Aufgaben bearbeitet werden müssen, welche den Einsatz des Kurzzeitgedächtnisses erfordern.

Das Messinstrument, das zur Messung eines bestimmten Merkmals herangezogen wird, sollte natürlich auch dafür geeignet sein, dieses Merkmal zu messen und den **psychometrischen Gütekriterien** genügen. Zu den Hauptgütekriterien des psychologischen Testens und Messens zählen Objektivität, Reliabilität und Validität:

Objektivität: Eine Messung gilt als objektiv, wenn die Messung nicht dadurch beeinflusst wird, welche Person (= Versuchsleitung) das Messinstrument einsetzt. Kommen verschiedene Versuchsleitungen bei derselben Versuchsperson zum gleichen Testergebnis, kann von einer objektiven Messung gesprochen werden. Die Objektivität betrifft sowohl die Durchführung als auch die Auswertung und Interpretation von Messungen.

KAPITEL 3. PSYCHOLOGISCHE FORSCHUNG UND METHODENLEHRE

Reliabilität: Unter Reliabilität versteht man die Zuverlässigkeit und Messgenauigkeit eines Messinstruments. Die Reliabilität kann anhand der Reproduzierbarkeit des Messergebnisses geschätzt werden: Messungen desselben Objekts sollen bei wiederholter Durchführung zu gleichen Ergebnissen führen – sofern sich die Eigenschaften des Objekts nicht verändern.

Validität: Ein Messinstrument gilt als valide, wenn es inhaltlich das misst, was es zu messen vorgibt. Bei Messinstrumenten wie einer Waage oder einem Thermometer ist dies augenscheinlich. Eine Waage misst das Gewicht und ein Thermometer die Temperatur. Doch bei der Messung von psychologischen Eigenschaften ist das weniger eindeutig. Wird beispielsweise der Puls als Indikator für das Stresserleben gemessen, kann der Puls aber auch durch andere Faktoren wie Nervosität oder körperliche Betätigung beeinflusst werden und das Messergebnis spiegelt in Wahrheit nicht (nur) das Stresserleben wider.

Messungen können verschiedene Mess- bzw. **Skalenniveaus** haben. Die Skalenniveaus unterscheiden sich in der Hinsicht, wie informationshaltig die erzeugten Messungen sind und welche Relationen zwischen den Werten durch die jeweilige Skala abgebildet werden können, was wiederum einen Einfluss auf die statistische Datenanalyse hat. Zu wissen, welches Skalenniveau die erhobenen Variablen haben, ist daher auch wichtig für das Verständnis, welche Informationen aus den Daten gezogen werden und wie diese interpretiert werden können (Döring, 2023). Einen Überblick über die verschiedenen Skalenniveaus finden Sie in Tabelle 3.2.

Tabelle 3.2: Überblick über die verschiedenen Skalenniveaus

Skalenniveau	Beschreibung	mögliche Aussagen	Beispiele
Nominalskala	verschiedene Kategorien, Klassifikation	Gleichheit bzw. Verschiedenheit	Vorhandensein/Fehlen einer Erkrankung (dichotom), Beruf, Nationalität
Ordinalskala	Rangordnung ist definiert	Größer-Kleiner-Gleich-Relationen	Schulnoten (1–5), höchster Bildungsabschluss
Intervallskala	Rangordnung und Abstände definiert	Gleichheit/Verschiedenheit von Intervallen	Temperatur in Celsius, psychische Eigenschaften wie Intelligenz und Gewissenhaftigkeit
Verhältnisskala	Rangordnung, Abstände und natürlicher Nullpunkt definiert	Gleichheit/Verschiedenheit von Verhältnissen	Temperatur in Kelvin, Längenmaße, Gewicht, Reaktionszeit in Sekunden

Bei einer **Nominalskala** steht die Relation der Verschiedenheit bzw. Gleichheit von Objekten im Vordergrund. Sie gilt allgemein als jene Skala mit dem niedrigsten Skalenniveau, weil aus den Daten lediglich geschlussfolgert werden kann,

KAPITEL 3. PSYCHOLOGISCHE FORSCHUNG UND METHODENLEHRE

dass zwei Objekte die gleiche Ausprägung oder verschiedene Ausprägungen eines Merkmals aufweisen. Die im Rahmen der Messung vorgenommene Zuordnung von Zahlen zu Merkmalsausprägungen geschieht willkürlich.

Beispiel: Ein Beispiel für eine Variable mit Nominalskala ist die Nationalität einer Person. Mögliche Merkmalsausprägungen der Nationalität wären (u. a.) Österreich, Deutschland, Italien und Ungarn. Wenn die Nationalität gemessen wird, kann der Nationalität Österreich die Zahl 1 und der Nationalität Deutschland die Zahl 2 zugeordnet werden, die Zuordnung könnte aber auch umgekehrt erfolgen (Deutschland = 1, Österreich = 2). Dies ist möglich, weil es keine Rangordnung zwischen den Zahlen gibt und die verschiedenen zugeordneten Zahlen lediglich zum Ausdruck bringen, ob zwei Personen die gleiche Merkmalsausprägung oder verschiedene Merkmalsausprägungen haben. Man könnte auch völlig andere Zahlen vergeben und es würde keinen Unterschied in der Interpretation machen (Sedlmeier & Renkewitz, 2013).

Ein Spezialfall von Variablen mit Nominalskalenniveau sind **dichotome Variablen**. Dichotome Variablen haben nur zwei Merkmalsausprägungen und sind häufig dann anzutreffen, wenn man erheben möchte, ob ein Merkmal vorhanden ist oder nicht. So wäre das Vorhandensein/Fehlen einer Erkrankung (0 = keine Erkrankung, 1 = Erkrankung) ein Beispiel für eine dichotome Variable (Sedlmeier & Renkewitz, 2013).

Bei einer **Ordinalskala** existiert eine Ordnung zwischen den einzelnen Ausprägungen der Variablen. Es wird gemessen, ob etwas kleiner, stärker oder genauso groß ist wie etwas anderes. Ordinalskalierte Werte geben also Aufschluss darüber, wie ein Objekt auf einer Skala im Vergleich zu anderen einzuordnen ist und es ergibt sich eine Rangordnung. Sie erlauben jedoch keine Aussage darüber, wie groß der Unterschied zwischen zwei Objekten hinsichtlich des gemessenen Merkmals ist (Sedlmeier & Renkewitz, 2013).

Beispiel: Ein Beispiel für ein ordinalskaliertes Merkmal ist der höchste Bildungsabschluss. Es kann zwar eindeutig festgestellt werden, dass ein Masterabschluss ein höherer akademischer Abschluss ist als ein Bachelorabschluss oder ein Pflichtschulabschluss, es kann jedoch keine Aussage über den Abstand zwischen den einzelnen Ausprägungen getroffen werden. Es ist nicht bekannt, welcher Abstand zwischen einem Pflichtabschluss und einem Bachelorabschluss oder einem Bachelorabschluss und einem Masterabschluss vorliegt. Folglich kann auch kein sinnvoller Mittelwert im Sinne des arithmetischen Mittels gebildet werden. Andere Beispiele für Merkmale mit Ordinalskalenniveau wären Schulnoten(1–5) oder militärische Ränge.

Bei einer **Intervallskala** existiert nicht nur eine Ordnung zwischen den Ausprägungen des Merkmals, sondern auch die Abstände zwischen den einzelnen Ausprägungen sind definiert. Die Messwerte werden so den Merkmalsausprägungen zugeordnet, dass gleiche Unterschiede in den Messwerten auch gleiche Unterschiede in den Merkmalsausprägungen darstellen. Intervallskalierte Daten erlauben jedoch keine Aussagen über das Verhältnis zwischen verschiedenen Merkmalsausprägungen (z. B. etwas ist doppelt so groß).

KAPITEL 3. PSYCHOLOGISCHE FORSCHUNG UND METHODENLEHRE

Beispiel: Ein klassisches Beispiel für eine intervallskalierte Skala ist die Temperatur in Grad Celsius. Der Abstand zwischen 2 °C und 4 °C ist gleich groß wie der Abstand zwischen 6 °C und 8 °C. Man kann jedoch nicht sagen, dass 8 °C doppelt so warm ist wie 4 °C, da es keinen natürlichen Nullpunkt gibt, sondern 0 °C definiert ist, als die Temperatur, bei der Wasser ihren Aggregatzustand von fest auf flüssig ändert. Auch psychische Merkmale werden meist als intervallskalierte Variablen behandelt: eine Person kann in einem Intelligenztest mehr Punkte erreichen als eine andere Person und das Intervall zwischen den beiden Messwerten kann ermittelt werden, einen natürlichen Nullpunkt im Sinne von „keine Intelligenz“ gibt es aber nicht (Sedlmeier & Renkewitz, 2013).

Bei einer **Verhältnisskala**, auch Ratio-Skala genannt, gibt es eine Ordnung zwischen den Ausprägungen des Merkmals, die Abstände zwischen den einzelnen Ausprägungen sind definiert und es gibt – im Unterschied zur Intervallskala – einen natürlichen Nullpunkt, der es ermöglicht, dass auch die Verhältnisse zwischen den einzelnen Merkmalsausprägungen interpretiert werden können. Ein Beispiel für Merkmale mit Verhältnisskalenniveau sind die Temperatur in Grad Kelvin, weil es bei dieser – im Gegensatz zur Temperatur in Grad Celsius – einen natürlichen Nullpunkt gibt – die geringste mögliche Temperatur. Auch gängige Längen- und Gewichtsmaße sind verhältnisskaliert (Sedlmeier & Renkewitz, 2013).

Beispiel: Ein verhältnisskaliertes Merkmal, das häufig in der psychologischen Forschung gemessen wird, ist die Reaktionszeit. Aufgrund der Verhältnisskala dieses Merkmals ist es möglich, sowohl Aussagen zu den Unterschieden zwischen zwei Reaktionszeiten als auch zu deren Verhältnis zu treffen. Man könnte beispielsweise sagen, dass nach Alkoholkonsum die Reaktionszeit einer Person bei einer Aufgabe dreimal so lang ist wie im nüchternen Zustand.

Eine weitere Unterscheidung kann zwischen kategorialen und kontinuierlichen Variablen getroffen werden. Bei **kategorialen Variablen** ist nur eine abzählbare Menge von Ausprägungen in spezifischen Kategorien möglich und die Anzahl der Kategorien, aus denen auszuwählen ist, ist in der Regel begrenzt. Bei **kontinuierlichen Variablen** können beliebige Ausprägungen auf einem Kontinuum angenommen werden. Variablen mit einem nominalen oder ordinalen Skalenniveau zählen zu den kategorialen Variablen, Variablen mit einer Intervallskala oder einer Verhältnisskala zu den kontinuierlichen Variablen. Im Zuge der Operationalisierung werden gewöhnlich qualitative Merkmale in kategoriale Variablen und quantitative Merkmale in kontinuierliche Variablen überführt. In Abhängigkeit von der Operationalisierung und der Wahl des Messinstrumentes können jedoch quantitative Merkmale auch in kategoriale Variablen überführt werden. Möchte man z. B. etwas über die Putzgewohnheiten einer Person erfahren und fragt danach, wie häufig das Badezimmer geputzt wird, gibt es unterschiedliche Möglichkeiten die jeweilige Ausprägung zu erheben (siehe Abbildung 3.6). Im ersten Fall gibt es vordefinierte Kategorien und die Variable kann genau vier verschiedene Ausprägungen annehmen – es handelt sich daher um eine kategoriale Variable, auch wenn das latente Merkmal „Reinlichkeit“ als quantitatives Merkmal angesehen werden würde. Bei der zweiten Frage haben die Personen ein offenes Antwortformat und können je-

KAPITEL 3. PSYCHOLOGISCHE FORSCHUNG UND METHODENLEHRE

den beliebigen Wert eintragen – es ergibt sich eine kontinuierliche Variable.

Wie häufig putzen Sie Ihr Badezimmer?

☐ mehrmals pro Woche ☐ einmal pro Woche ☐ alle 2 Wochen ☐ seltener als alle 2 Wochen

Wie häufig putzen Sie Ihr Badezimmer?

_____ mal pro Monat

Abbildung 3.6: Beispiel für unterschiedliche Antwortformate in einem Fragebogen

3.3.3 Stichproben

In der Psychologie werden in der Regel Menschen untersucht, da man Erkenntnisse über das Erleben und Verhalten von Menschen erhalten möchte. Die Gesamtheit der Fälle, über die in einer psychologischen Studie etwas ausgesagt werden soll, wird als **Population** oder auch als Grundgesamtheit bezeichnet. Ein Beispiel für eine Population im Sinne der Forschung könnte beispielsweise die Gesamtheit aller Menschen sein. Es könnte aber auch sein, dass man sich im Rahmen einer Forschungsfrage nur für Personen, die regelmäßig Sport treiben, interessiert. Dann bestünde die Population aus allen Personen, die regelmäßig Sport treiben. Möchte man nur Aussagen über Frauen zwischen 18 und 25 Jahren treffen, die in Österreich leben, dann bestünde die Population aus allen Personen, auf die diese Kriterien zutreffen.

Da es in der psychologischen Forschung annähernd nie möglich ist, eine Vollerhebung durchzuführen, bei der alle Angehörigen der jeweiligen Population untersucht werden, werden in der Regel Stichproben aus der zu untersuchenden Population gezogen. Eine **Stichprobe** ist eine Teilmenge aus der Population, die unter bestimmten Gesichtspunkten ausgewählt wurde. Jene Personen, die Teil der Stichprobe sind, werden als **Versuchspersonen** oder auch **Proband:innen** bezeichnet. Ein Anspruch an die Stichprobe ist, dass die Ergebnisse, welche anhand dieser Stichprobe gewonnen werden, auf die jeweilige Population übertragen werden können. Dafür ist es notwendig, dass die Stichprobe alle erhobenen Merkmale der Population adäquat darstellt und repräsentiert, weswegen man in diesem Zusammenhang auch von der **Repräsentativität** der Stichprobe spricht. Repräsentiert die Stichprobe die Population, stellt die Stichprobe hinsichtlich der untersuchten Merkmale eine Art Miniaturabbild der Population dar (Döring, 2023; Hussy et al., 2013). Eine repräsentative Stichprobe ist eine Voraussetzung dafür, dass das Gütekriterium der externen Validität erfüllt wird (siehe Infobox 3.4).

Die Forderung nach Repräsentativität erfüllen in erster Linie **Zufallsstichproben**. Bei einer Zufallsstichprobe hat jede Person, die der Population angehört, die gleiche Chance in die Stichprobe aufgenommen zu werden. In der Praxis ist diese

KAPITEL 3. PSYCHOLOGISCHE FORSCHUNG UND METHODENLEHRE

Forderung jedoch meist schwer umzusetzen. Stellen Sie sich vor, Sie interessieren sich für die psychische Gesundheit der Studierenden an einem Universitätsstandort und Ihnen liegt eine Auflistung aller Studierenden (Population) vor. Sie sind sehr darum bemüht, eine Zufallsstichprobe an Studierenden zur psychischen Gesundheit zu befragen und senden daher einen Fragebogen an Studierende, welche durch ein Zufallsverfahren aus der Population ausgewählt wurden, mit der Bitte diesen ausgefüllt zurückzusenden. In der Praxis werden Sie jedoch nicht von allen Studierenden den Fragebogen retourniert bekommen, möglicherweise, weil manche Studierende ihre Mails nicht regelmäßig ansehen, oder einfach keine Lust haben, den Fragebogen zu bearbeiten.

Es könnte aber auch sein, dass vor allem diejenigen, deren psychische Gesundheit eher schlechter bewertet werden würde, den Fragebogen nicht ausfüllen, weil sie keine Angaben dazu machen wollen. In diesem Fall hätten Sie zwar versucht, eine Zufallsstichprobe zu generieren, durch die unterschiedliche Bereitschaft der Studierenden den Fragebogen zu bearbeiten, ist die Stichprobe schlussendlich aber dennoch verzerrt und die von der Stichprobe berichtete psychische Gesundheit überschätzt wahrscheinlich die tatsächliche psychische Gesundheit unter den Studierenden. Man spricht in diesem Fall auch vom **Selection Bias** – eine Verzerrung in den Daten, welche dadurch zustande kommt, dass die Auswahl der Stichprobe nicht völlig zufällig erfolgt ist (siehe auch Abbildung 3.7).




Abbildung 3.7: Die Teilnehmenden einer Statistikkonferenz als Referenz dafür zu verwenden, wie allgemein bekannt der Begriff des *Selection Bias* ist, führt zu Daten, welche dem *Selection Bias* unterliegen

Üblicherweise werden in der psychologischen Forschung aufgrund der wesentlich einfacheren Umsetzung **Gelegenheitsstichproben** herangezogen. Es werden Personen in die Stichprobe aufgenommen, bei denen gerade „eine günstige Gelegenheit“ besteht, sie ohne großen Aufwand zu untersuchen. An Universitäten werden daher häufig Studierende, welche über Ausschreibungen und Aushänge an der Universität rekrutiert werden, untersucht (siehe Abbildung 3.8). Ein anderes Beispiel für Gelegenheitsstichproben sind Online-Umfragen. Wenn Sie eine solche Umfrage sehen, können Sie selbst entscheiden, ob es für Sie gerade günstig ist, daran teilzunehmen oder nicht. Somit besteht die Stichprobe aus Personen, die sich für die Umfrage Zeit nehmen konnten oder wollten. Der Nachteil an Gelegenheitsstichproben ist, dass nicht ausgeschlossen werden kann, dass beispielsweise hauptsächlich Personen mit einer gewissen Merkmalsausprägung teilgenommen haben, was Auswirkungen auf die Ergebnisse der Untersuchungen hat. Da



Abbildung 3.8: Bei vielen psychologischen Studien werden aufgrund der Verfügbarkeit primär Psychologiestudierende untersucht. Dies kann zu einem Selection Bias führen, wenn sich die Ausprägungen des untersuchten Merkmals in der Population der Psychologiestudierenden systematisch von denen der eigentlichen Zielpopulation unterscheiden; Abbildung aus Huber (2019, S. 112).

das Ausmaß dieser Auswirkungen nicht abschätzbar ist, führt dies dazu, dass die Stichprobe als Schätzung für die Population ungeeignet ist (Döring, 2023).

Neben der Art und Weise wie die Stichprobe gewonnen wird, spielt auch die Größe der Stichprobe eine Rolle. Der **Stichprobenumfang** ist die Anzahl der Personen, die der Stichprobe angehören. Mit zunehmendem Stichprobenumfang steigt die Aussagekraft der Ergebnisse, da einzelne „Ausnahmen“ das Gesamtergebnis nicht so stark beeinflussen, aber auch der Verbrauch von Ressourcen, welcher mit der Untersuchung all dieser Personen verknüpft ist. Es ist daher wichtig, ausreichend viele, aber nicht zu viele Versuchspersonen in die Stichprobe aufzunehmen (Döring, 2023).

3.3.4 Studiendesigns

Das Design einer Studie gibt vor, wie die Studie durchgeführt werden soll. Zum Design einer Studie gehört die Auswahl der Versuchspersonen, die Wahl der Gruppen an Personen, die man vergleichen möchte, Methoden der Datenerhebung und der zeitliche Horizont (Sedlmeier & Renkewitz, 2013). Das Studiendesign ist maßgeblich von der Hypothese vorbestimmt. Liegt beispielsweise eine Unterschiedshypo-

KAPITEL 3. PSYCHOLOGISCHE FORSCHUNG UND METHODENLEHRE

these vor, inwiefern sich Personen, die sich in einem Merkmal unterscheiden, auch in einem anderen Merkmal unterscheiden, ist es für die Untersuchung notwendig, mehrere Gruppen zu bilden, die sich hinsichtlich des ersten Merkmals unterscheiden. Anschließend wird untersucht, ob sich diese Gruppe an Personen auch im zweiten Merkmal unterscheidet. Liegt eine Veränderungshypothese vor, so wird es notwendig sein, das Merkmal zu verschiedenen Zeitpunkten zu erheben, um herauszufinden, ob sich dieses Merkmal über die Zeit verändert hat. Möchte man beispielsweise die Effektivität einer Therapie untersuchen, so ist es notwendig, zu mindestens zwei Zeitpunkten eine Messung vorzunehmen: vor der Therapie und nach der Therapie.

Müssen die Versuchspersonen für die Untersuchung in ein Labor kommen, handelt es sich um eine **Laboruntersuchung**. Werden die Versuchspersonen hingegen in ihrer natürlichen Umgebung untersucht, spricht man von einer **Felduntersuchung**. Felduntersuchungen haben den Vorteil, dass sich die Versuchspersonen in der natürlichen Umgebung authentisch verhalten und daher die Ergebnisse, die in der Untersuchung gewonnen werden, auch besser auf andere, ähnliche Situationen übertragbar sind. Manche Verhaltensweisen lassen sich auch nur im natürlichen Umfeld beobachten. Felduntersuchungen haben allerdings den Nachteil, dass Faktoren, die die Untersuchung möglicherweise stören, nicht so gut kontrolliert werden können wie in einer Laboruntersuchung. Felduntersuchungen resultieren in einer geringeren internen Validität und einer größeren externen Validität als Laboruntersuchungen (siehe Infobox 3.4). Weitere wichtige Faktoren in der Struktur und im Ablauf einer Untersuchung werden im folgenden Kapitel 3.4 behandelt.

Infobox 3.4: Interne und externe Validität

Die interne und externe Validität stellen Unterformen der Validität dar und werden als Gütekriterien bei psychologischen Untersuchungen, insbesondere Experimenten (siehe Kapitel 3.4) gefordert. Eine psychologische Untersuchung erfüllt das Kriterium der **internen Validität**, wenn sie einen eindeutigen Kausalschluss zulässt. Kausalschlüsse sind dann zulässig, wenn neben der beobachteten Kovariation die Kausalrichtung eindeutig bestimmt werden kann und andere Variablen als Ursache für den Zusammenhang ausgeschlossen werden können (vgl. Infobox 3.3). Die **externe Validität** bezieht sich darauf, ob die Ergebnisse eines Experiments auch auf andere Personen, die nicht Teil des Experiments waren, und andere Situationen übertragen werden können. Die externe Validität kann erhöht werden, wenn eine möglichst repräsentative Stichprobe für das Experiment gewählt wird, und ist davon abhängig, wie sehr die Untersuchungssituation auf Alltagssituationen übertragen werden kann (Sedlmeier & Renkewitz, 2013).

3.4 Die experimentelle Methode

Der Ausdruck „man macht bzw. wagt ein Experiment“ ist auch in der Alltagssprache verbreitet. Man meint damit, dass man etwas Neues ausprobiert, dessen Ausgang ungewiss ist. Wissenschaftliche Experimente als Forschungsmethode sind insbesondere durch die folgenden zwei Merkmale charakterisiert. Die Bedeutung dieser zwei Merkmale mag an dieser Stelle vielleicht noch nicht ganz klar sein, das sollte sich aber im Laufe dieses Kapitels ändern.

1. Es wird mindestens eine Variable systematisch variiert und anschließend beobachtet, welchen Effekt diese Variable auf eine oder mehrere andere Variablen hat.
2. Die Wirkung anderer Variablen (Störvariablen) wird mittels Techniken zur Kontrolle ausgeschaltet oder kontrolliert.

Experimente haben zum Ziel **Ursache-Wirkungs-Hypothesen** zu überprüfen. Das heißt, man möchte etwas über die Kausalität zwischen zwei oder mehreren Variablen aussagen. Experimente gelten als die aussagekräftigste wissenschaftliche Methode, denn damit man von einer Kausalitätsbeziehung zwischen zwei Variablen sprechen kann, sind




Abbildung 3.9: Kovariation bzw. Korrelation ist nicht gleichbedeutend mit Kausalität. Welche anderen Ursachen wären hier denkbar?

– wie bereits in Infobox 3.3 erläutert wurde – neben der Kovariation der Variablen zwei weitere Voraussetzungen zu erfüllen: Zum einen muss sichergestellt werden, dass die verursachende Variable zeitlich vor der beeinflussten Variable auftritt und zum anderen müssen andere Variablen als Ursache ausgeschlossen werden können (siehe Abbildung 3.9).

Die zeitliche Abfolge wird in Experimenten dadurch sichergestellt, dass die Variable, von der vermutet wird, dass sie einen ursächlichen Charakter hat, systematisch variiert und deren Effekt auf andere Variablen beobachtet wird. Die ursächliche Variable wird in Experimenten als **unabhängige Variable** (UV) bezeichnet. Je-ne Variable, welche mutmaßlich durch die unabhängige Variable beeinflusst wird, heißt **abhängige Variable** (AV) – sie hängt von der unabhängigen Variable ab. Damit andere Variablen, welche als **Störvariablen** bezeichnet werden, als Ursache ausgeschlossen werden können, wird versucht, diese Variablen zu kontrollieren beziehungsweise deren Wirkung auszuschalten. Sind die nötigen Bedingungen, welche einen Kausalschluss zulassen, vollständig erfüllt, wird ein Experiment auch als **intern valide** bezeichnet (siehe Infobox 3.4; Renner et al., 2012; Grabowski et al., 2007). In den folgenden Unterkapiteln wird näher darauf eingegangen, in welcher Art und Weise die für einen Kausalschluss nötigen Bedingungen hergestellt werden.

3.4.1 Sicherstellung der zeitlichen Abfolge

Damit die zeitliche Abfolge der Variablen sichergestellt werden kann, werden in einem Experiment die verschiedenen Ausprägungen der unabhängigen Variablen vom Versuchsleiter / von der Versuchsleiterin hergestellt. Es ist auch die Rede davon, dass die unabhängige Variable *manipuliert* wird. Möchte man beispielsweise untersuchen, ob Personen, die zu wenig schlafen und schlafdepriviert sind, eine langsamere Reaktionszeit haben als Personen, die ausreichend schlafen, so wäre die unabhängige Variable die Schlafdeprivation mit den Ausprägungen *ja* und *nein*, welche manipuliert wird, und die Reaktionszeit wäre die abhängige Variable. Die Manipulation der unabhängigen Variable kann in einem Experiment realisiert werden, indem beispielsweise zwei Gruppen gebildet werden und die Versuchspersonen jeweils einer dieser beiden Gruppen per Zufall zugeordnet werden. Ein solches Studiendesign, bei dem die Versuchspersonen auf verschiedene Gruppen aufgeteilt werden, wird als **Between-Subjects-Design bezeichnet** (siehe Infobox 3.5).

Handelt es sich bei den beiden Bedingungen um eine Situation, in der die UV entweder gegeben (Schlafdeprivation) oder nicht gegeben ist (keine Schlafdeprivation), spricht man auch von einer **Experimentalbedingung** (Schlafdeprivation) und einer **Kontrollbedingung** (keine Schlafdeprivation). Bei der Durchführung des Experiments könnten jene Personen, die der **Experimentalgruppe** angehören, aufgefordert werden, in der Nacht vor der Reaktionszeitaufgabe nicht mehr als vier Stunden zu schlafen, wohingegen Personen, die der **Kontrollgruppe** angehören, aufgefordert werden, ausreichend viel zu schlafen, damit sie sich wach und erholt fühlen. Am Morgen danach wird dann bei allen Versuchspersonen die Reaktionszeit bei einer Aufgabe gemessen. Die Reaktionszeit stellt im Experiment die abhängige Variable dar. Im Anschluss werden die Reaktionszeiten der Versuchspersonen der Experimentalgruppe mit den Versuchspersonen der Kontrollgruppe verglichen und analysiert, ob es Unterschiede zwischen den beiden Gruppen gibt. Dadurch, dass die unabhängige Variable im Experiment manipuliert wird, kann ausgeschlossen werden, dass eine Kausalität in die entgegengesetzte Richtung besteht, nämlich, dass die Reaktionszeit bestimmt, ob Personen ausreichend schlafen oder nicht, und die Kovariation deswegen zustande gekommen ist. Während in diesem Beispiel die entgegengesetzte Kausalitätsrichtung recht unplausibel erscheint, gibt es andere Forschungsfragen, bei denen die Frage der Kausalität schwerer zu bestimmen ist. Es ist beispielsweise plausibel, dass die Lernmotivation das Ergebnis bei einer Prüfung beeinflusst, es könnte aber auch sein, dass gute Ergebnisse in Prüfungen auch die Lernmotivation steigern (Sedlmeier & Renkewitz, 2013).




Abbildung 3.10: Personen der Kontrollgruppe dienen dem Vergleich mit der Experimentalgruppe

Infobox 3.5: Between-Subjects-Design und Within-Subjects-Design

Bei einem Experiment mit einem **Between-Subjects-Design** gibt es zwei oder mehrere verschiedene Gruppen – in der Regel mindestens eine Experimentalgruppe und eine Kontrollgruppe – und die Versuchspersonen werden einer dieser Gruppen per Zufall zugeordnet. Das bedeutet, dass die Versuchspersonen jeweils nur an einer der experimentellen Bedingungen (Ausprägung der UV) teilnehmen. Von Interesse ist der Vergleich von Experimentalgruppe(n) und Kontrollgruppe. Dieses Studiendesign wird als Between-Subjects-Design bezeichnet, weil das experimentelle Vorgehen *zwischen* den Versuchspersonen variiert wird. Dem gegenüber stehen Experimente mit einem **Within-Subjects-Design**. Bei einem solchen Design durchlaufen alle Versuchspersonen alle Bedingungen des Experiments und anschließend werden die verschiedenen experimentellen Bedingungen innerhalb derselben Gruppe von Personen verglichen. Within-Subjects-Designs haben gegenüber Between-Subjects-Designs gewisse Vorteile (z. B. Ökonomie, mehr Daten), eignen sich jedoch bei manchen Fragestellung nicht, beispielsweise, wenn Vorwissen über den Versuchsablauf einen Einfluss auf die AV hat (Sedlmeier & Renkewitz, 2013).

3.4.2 Ausschluss von Alternativerklärungen

Neben der Kovariation und der eindeutigen zeitlichen Abfolge müssen als dritte Voraussetzung für einen Kausalschluss alle anderen Variablen als Ursache ausgeschlossen werden können. Dies ist die schwierigste zu erfüllende Voraussetzung bei Experimenten. Eine Störvariable kommt dann als Alternativerklärung infrage, wenn eine Kovariation zwischen der Störvariable und der abhängigen Variable besteht. Man spricht in diesem Fall auch von einer **Konfundierung**. Bezogen auf das oben genannte Experiment, in dem man untersuchen möchte, ob eine Schlafdeprivation einen Einfluss auf die Reaktionszeit hat, wäre beispielsweise die Tatsache, dass die Personen einer Gruppe motivierter und gewissenhafter sind und sich bei der Reaktionszeitaufgabe mehr anstrengen als die Personen der anderen Gruppe, eine mögliche Störvariable. Es wäre auch möglich, dass in einer Gruppe mehr ältere Personen sind, deren Reaktionszeiten altersbedingt länger sind als die der jüngeren Personen. In diesem Fall wäre das Alter der Versuchspersonen eine mögliche Störvariable. Um Konfundierungen ausschließen zu können, müssen mögliche Störvariablen kontrolliert werden (Sedlmeier & Renkewitz, 2013).




Abbildung 3.11: Beispiel dafür, welchen Einfluss eine Störvariable haben kann: Die Störvariable steht sowohl mit der AV (mehr motivierte Personen in einer der beiden Gruppen) als auch mit der UV in Zusammenhang (Motivation beeinflusst die Reaktionszeit), dadurch kovariert auch die UV mit der AV

Die Idee bei der Kontrolle von Störvariablen ist, dass mögliche Störvariablen entweder konstant gehalten oder ausbalanciert werden. Eine Variable kann **konstant gehalten** werden, indem beispielsweise der Versuchsablauf für alle Ver-

KAPITEL 3. PSYCHOLOGISCHE FORSCHUNG UND METHODENLEHRE

suchspersonen so ident wie möglich gehalten wird. Dazu gehört, dass die Instruktionen der Versuchspersonen in allen Bedingungen – sofern umsetzbar – gleich gehalten werden, der Versuch immer im gleichen Raum abgehalten wird und zur gleichen Tageszeit stattfindet. In der Praxis ist es jedoch kaum möglich, alle Merkmale der Untersuchungssituation durch Konstanthaltung zu kontrollieren, und man beschränkt sich auf Variablen, bei denen ein konfundierender Einfluss vermutet wird. Im oben genannten Beispiel ist der Versuchsraum für die Reaktionszeitaufgabe als mögliche Störvariable wahrscheinlich weniger relevant als die Tageszeit, an der die Aufgabe durchgeführt wird, oder die Anzahl der Personen, die sich im Raum befinden, während die Aufgabe bearbeitet wird.

Jedoch ist es nicht bei allen Variablen möglich, diese konstant zu halten. Das betrifft insbesondere Merkmale der Versuchspersonen (personengebundene Störvariablen), wie beispielsweise Alter, Geschlecht, Intelligenz und Motivation, aber auch situative Bedingungen, die möglicherweise ressourcenbedingt nicht konstant gehalten werden können. In diesem Fall versucht man sie zu **balancieren**. Eine Variable ist dann balanciert, wenn diese Variable in den verschiedenen Bedingungen des Experiments im Schnitt die gleiche Ausprägung aufweist. Wenn beispielsweise die Personen der beiden Gruppen im Schnitt das gleiche Alter aufweisen, gilt das Alter als balanciert und kann als konfundierende Variable ausgeschlossen werden, da das Alter in den verschiedenen Bedingungen einen ähnlichen Einfluss auf die AV ausübt (Sedlmeier & Renkewitz, 2013).

Die wichtigste Methode zur Balancierung möglicher Störvariablen ist die **Randomisierung**. Unter Randomisierung versteht man die zufällige Zuweisung der Versuchspersonen zu den Versuchsbedingungen. Durch die Randomisierung und eine ausreichend große Stichprobe kann angenommen werden, dass die Ausprägungen der Störvariablen in den verschiedenen Bedingungen ähnlich verteilt sind, weil die Versuchspersonen zufällig zugeordnet wurden. Die dadurch stattfindende Balancierung kontrolliert personengebundene Störvariablen. Die Randomisierung ist derart essentiell für ein Experiment, dass Untersuchungen, die dieses Kriterium nicht, aber alle anderen Kriterien erfüllen, nicht als Experimente, sondern als **Quasi-Experimente** bezeichnet werden. Manchmal ist eine Randomisierung und somit die Durchführung eines tatsächlichen Experiments nicht möglich. Das ist insbesondere dann der Fall, wenn die unabhängige Variable nicht manipuliert werden kann (Sedlmeier & Renkewitz, 2013). Denken Sie beispielsweise an den Vergleich von Personen mit und ohne Erkrankung. Die Erkrankung liegt entweder vor oder nicht vor und es ist nicht möglich, die Erkrankung hervorzurufen beziehungsweise zu heilen. Eine fehlende Randomisierung ist somit mit Einbußen für die interne Validität verbunden.

Vielleicht fragen Sie sich, warum man nicht die Ausprägungen der Störvariablen der Versuchspersonen im Vorfeld misst und die Personen dann gezielt je nach Ausprägung in die Gruppen aufteilt, um die Balancierung zu garantieren. Ein solches Vorgehen wird als **Parallelisieren** bezeichnet und findet dann Anwendung, wenn die Stichprobe eher klein ist und dadurch eine Randomisierung zur

KAPITEL 3. PSYCHOLOGISCHE FORSCHUNG UND METHODENLEHRE

Balancierung ungeeignet ist. Sinnvoll ist diese Technik jedoch nur dann, wenn von einer Variable bereits bekannt ist, dass sie wahrscheinlich einen konfundierenden Einfluss hat. Im Gegensatz zur Parallelisierung, durch die nur eine Störvariable kontrolliert werden kann, hat die Randomisierung (bei ausreichend großer Stichprobe) den Vorteil, dass sie mit relativ wenig Aufwand die Möglichkeit bietet, alle personengebundenen Störvariablen, bekannte sowie unbekannte, zu kontrollieren.

Auch die Anwendung eines Within-Subjects-Design stellt eine Möglichkeit dar, personengebundene Störvariablen zu kontrollieren. Da in allen Bedingungen dieselben Personen untersucht werden, findet eine perfekte Parallelisierung statt. Wie in Infobox 3.5 bereits angesprochen wurde, ist die Umsetzung eines solchen Designs jedoch nicht immer möglich (Sedlmeier & Renkewitz, 2013).

3.4.3 Erwartungseffekte und deren Kontrolle

Personen, die an einem Experiment teilnehmen, machen dies mit gewissen Vorstellungen und Erwartungen. Sie reagieren nicht nur passiv auf die Geschehnisse im Experiment, sondern nehmen aktiv daran teil. So kann bereits das bloße Wissen der Versuchspersonen, dass sie an einem Experiment teilnehmen und beobachtet werden, deren Verhalten verändern. Wenn Menschen wissen, dass sie beobachtet und bewertet werden, versuchen sie beispielsweise einen guten Eindruck zu hinterlassen. Dieses Phänomen ist als **Reaktivität** oder auch **Hawthorne-Effekt** bekannt – benannt nach Experimenten von Roethlisberger und Dickson (1939) in den Hawthorne-Werken, bei denen sich die Arbeitsleistung trotz Verschlechterung der Arbeitsbedingungen verbesserte, was darauf zurückgeführt wurde, dass die Personen wussten, dass sie beobachtet werden^C (Hussy et al., 2013). Reaktive Verhaltensweisen stellen insofern ein Problem dar, als dass die interne Validität gefährdet ist, weil die Erwartung der Versuchspersonen einen konfundierenden Einfluss hat.

Es gibt verschiedene Strategien, die das Problem der Reaktivität verringern können. Eine Möglichkeit ist, dass den Versuchspersonen eine Coverstory über den Untersuchungszweck erzählt wird und sie über den wahren Untersuchungszweck im Dunklen gelassen werden. Ob dies zulässig ist, ist jedoch auch eine Frage der Ethik, weil die Versuchspersonen grundsätzlich vor ihrer Teilnahme über das Experiment aufgeklärt werden müssen. Eine andere Möglichkeit ist es, dass Maße erhoben werden, welche nur schwer verfälscht werden können, dazu zählen beispielsweise bildgebende Verfahren zur Abbildung der Gehirnaktivität oder Hormonspiegelmessungen. Auch implizite Messerverfahren wie beispielsweise der Implizite Assoziationstest (IAT), der in Kapitel 8.3.4 näher behandelt wird, können eine Option darstellen, die Reaktivität zu verringern (Hussy et al., 2013).

^CObwohl der Hawthorne-Effekt zu den bekanntesten Effekten in der Psychologie zählt, ist fraglich, ob es den Effekt in der ursprünglich angenommenen Form tatsächlich gibt, weil er nicht repliziert werden konnte (Jones, 1992). Er hat jedoch maßgeblich zur Veränderung der Arbeitswelt beigetragen (Human Relations Bewegung).

KAPITEL 3. PSYCHOLOGISCHE FORSCHUNG UND METHODENLEHRE

Erwartungen der Versuchspersonen können auch unbewusst das Erleben und Verhalten beeinflussen. Das zeigt der **Placebo-Effekt** (siehe Abbildung 3.12), der vor allem aus Studien zur Medikamentenwirksamkeit bekannt ist. Als Placebo wird ein vermeintliches Medikament bezeichnet, das zwar aussieht wie ein Medikament, aber keinerlei relevanten Wirkstoff enthält. Der Placebo-Effekt beschreibt eine positive Veränderung des Gesundheitszustandes nach Einnahme eines Placebos, die auf den psychosozialen Kontext der Behandlung zurückzuführen ist, wie beispielsweise der Erwartung der Versuchsperson, dass das Medikament im erwünschten Sinn wirken wird. Um zu kontrollieren, dass positive Effekte nach der Einnahme eines Medikaments auch tatsächlich auf das Medikament zurückgeführt werden können, bekommen manche Versuchspersonen das echte Medikament und andere Personen das Placebo verabreicht. Die Versuchspersonen wissen dabei nicht, ob sie der Experimentalgruppe (echtes Medikament) oder der Kontrollgruppe (Placebo) angehören, müssen aus ethischen Gründen aber im Vorfeld darüber aufgeklärt werden, dass sie möglicherweise keine wirksame Behandlung erfahren. Wissen die Versuchspersonen nicht, ob sie Teil der Experimental- oder der Kontrollgruppe sind, spricht man auch von einem **Blindversuch**. Durch den Vergleich der Gruppen kann analysiert werden, welche Veränderungen tatsächlich auf die Wirksamkeit des Medikaments zurückzuführen sind und welche Veränderungen durch die Erwartungshaltung oder andere psychosoziale Faktoren zustande kommen. Placebo-Effekte sind jedoch nicht auf die Medikamentenforschung beschränkt, sondern können auch in anderen Forschungsbereichen auftreten, nämlich immer dann, wenn die Versuchsperson glaubt, eine wirksame Behandlung zu erfahren, obwohl dies nicht der Fall ist. Das Gegenstück zum Placebo-Effekt ist der **Nocebo-Effekt** (siehe Abbildung 3.12). Darunter werden unerwünschte Wirkungen nach Erfahrung einer nicht wirksamen Behandlung zusammengefasst (Sedlmeier & Renkewitz, 2013).

Doch nicht nur die Erwartungen der Versuchspersonen können einen konfundierenden Einfluss haben, sondern auch die Erwartungen der Versuchsleitung. In




Abbildung 3.12: Der Placebo-Effekt und der Nocebo-Effekt entstehen durch die Erwartungen der Versuchspersonen

KAPITEL 3. PSYCHOLOGISCHE FORSCHUNG UND METHODENLEHRE

einem Experiment von Rosenthal und Fode (1963) sollten Studierende Ratten so trainieren, dass sie anschließend den Weg durch ein Labyrinth zu einer Futterquelle finden. Die Hälfte der Studierenden erhielt im Vorfeld den Hinweis, dass ihre Ratten besonders intelligent seien, die andere Hälfte der Versuchspersonen, dass es sich bei ihren Ratten um besonders dumme Ratten handle. In Wahrheit waren die Ratten zufällig den Versuchsbedingungen zugeordnet worden und über deren Intelligenz war nichts bekannt. Als Ergebnis dieses Experiments zeigte sich, dass sich die vermeintlich intelligenten Ratten nach und nach immer verbesserten, während bei den dummen Ratten nahezu keine Verbesserung beobachtet werden konnte. Die Erwartungen der Studierenden hatte beeinflusst, wie gut die Ratten bei der Aufgabe waren, weil sie beispielsweise mehr Zeit in die Aufgabe investiert haben. Der Effekt, der auf die Erwartungen der Versuchsleitung zurückzuführen ist, wird daher auch als **Rosenthal-Effekt** bezeichnet. Der Rosenthal-Effekt ist kein von der Versuchsleitung beabsichtigter Effekt, sondern wirkt wie eine selbsterfüllende Prophezeiung (siehe Infobox 3.6).

Der Rosenthal-Effekt kann kontrolliert werden, indem die Versuchsleitung selbst nicht weiß, was zu erwarten ist und im Unklaren darüber ist, ob die betreffende Versuchsperson der Experimental- oder der Kontrollgruppe angehört. Untersuchungen, bei denen weder die Versuchsperson noch die Versuchsleitung wissen, welcher Versuchsbedingung die Versuchsperson zugeordnet wurde, werden als **Doppelblindstudien** bezeichnet (siehe Abbildung 3.13). Es muss aber natürlich nachträglich nachvollziehbar sein, welcher Bedingung die Versuchspersonen zugeteilt waren, beispielsweise durch eine dritte Person, die nicht direkt mit der Versuchsperson interagiert (Sedlmeier & Renkewitz, 2013).




Abbildung 3.13: Bei Doppelblindstudien wissen weder die Versuchsperson noch die Versuchsleitung, welcher Versuchsbedingung die Versuchsperson zugeordnet ist; Abbildung aus Huber (2019, S. 186)

Infobox 3.6: Selbsterfüllende Prophezeiung

Eine selbsterfüllende Prophezeiung ist eine Vorhersage, die ihre Erfüllung selbst bewirkt. Die Vorhersage über ein zukünftiges Verhalten oder Ereignis verändert das eigene Verhalten derart, dass das Vorhergesagte auch tatsächlich eintritt. Ein wesentlicher Faktor dabei ist, dass die Menschen an die Vorhersage glauben und es zu einer positiven Rückkopplung zwischen Erwartung und Verhalten kommt. Selbsterfüllende Prophezeiungen spielen neben dem Rosenthal-Effekt auch beim Placebo- und Nocebo-Effekt eine Rolle. Beim Placebo- bzw. Nocebo-Effekt erwarten die Personen eine Wirkung und die Erwartung bewirkt, dass sie ihre Aufmerksamkeit auf mögliche Veränderungen richten, die zum erwarteten Effekt passen, und diese schließlich auch wahrnehmen (Merton, 1948; Gerrig et al., 2018).

3.5 Deskriptive Statistik

Hat eine Forschungsgruppe eine Studie durchgeführt und die jeweiligen Daten erhoben, ist noch offen, was diese erhobenen Daten nun für eine Bedeutung haben. Durch statistische Analysen können Forschende herausfinden, ob ihre Vorhersagen richtig sind. In diesem Kapitel werden gängige Kennwerte und Darstellungsformen der **deskriptiven Statistik** behandelt. Die deskriptive Statistik wird auch beschreibende Statistik genannt, weil die Verfahren, die zur deskriptiven Statistik zählen, zum Ziel haben, die Daten der Stichprobe zu beschreiben. Davon unterscheidet sich die **Inferenzstatistik**, auch schließende Statistik genannt, welche darauf abzielt, mithilfe der Wahrscheinlichkeitstheorie von Daten der Stichprobe auf die der Population zu schließen (Gerrig et al., 2018).

Wenn Sie zurück an das Beispiel mit der Schlafdeprivation und der Reaktionszeit denken, dann könnte man anhand der deskriptiven Statistik die Stichprobe beschreiben und beispielsweise den Mittelwert der Reaktionszeit für beide Gruppen getrennt bilden. Möchte man jedoch von den Ergebnissen der Stichprobe auf Effekte in der Population schließen, werden Verfahren der Inferenzstatistik eingesetzt, die beispielsweise ermitteln, ob der Unterschied zwischen den beiden ermittelten Mittelwerten signifikant ist.




Abbildung 3.14: Mithilfe der deskriptiven Statistik erhält man zusammenfassende Informationen über die Stichprobe

Mithilfe der deskriptiven Statistik möchte man die Daten der Stichprobe zusammenfassend beschreiben und darstellen. Mit zusammenfassend ist gemeint, dass man nicht die einzelnen Werte der untersuchten Fälle betrachtet, sondern über mehrere beziehungsweise alle Fälle hinweg Aussagen tätigt. Zur deskriptiven Statistik zählen die Bestimmung von Häufigkeiten einzelner Werte und Häufigkeitsverteilungen, Kennwerte, welche etwas über die zentrale Tendenz sowie die Streuung einer Variable aussagen, und Zusammenhangsmaße, die Zusammenhänge zwischen zwei oder mehreren Variablen beschreiben. Oft werden Tabellen, Diagramme und Grafiken für die Darstellung der beschreibenden Statistik verwendet (Hussy et al., 2013).

3.5.1 Häufigkeiten und Häufigkeitsverteilungen

Neben den eigentlich relevanten Variablen des Experiments werden häufig auch noch weitere Merkmale wie das Geschlecht, die Nationalität oder das Alter der Versuchspersonen erhoben. Diese Merkmale dienen dazu, die Stichprobe zu beschreiben. Die Angabe von Häufigkeiten und Häufigkeitsverteilungen eignet sich insbesondere bei kategorialen Variablen, bei denen es nur eine abzählbare Menge an Ausprägungen in den jeweiligen Kategorien gibt (siehe auch Kapitel 3.3.2).

KAPITEL 3. PSYCHOLOGISCHE FORSCHUNG UND METHODENLEHRE

Bei der Angabe von Häufigkeiten kann zwischen absoluten und relativen Häufigkeiten unterschieden werden. Die **absoluten Häufigkeiten** geben die Anzahl der Werte pro Variablenausprägung an. Bezogen auf die Nationalität der Versuchspersonen könnte man angeben, dass 10 Personen aus Österreich, 8 Personen aus Deutschland und 2 Personen aus der Schweiz an der Untersuchung teilgenommen haben. Die **relativen Häufigkeiten** bezeichnen den Anteil der beobachteten Werte an allen Werten. Dazu werden die absoluten Häufigkeiten durch die Gesamtanzahl der Werte dividiert. Die relative Häufigkeit von Versuchspersonen aus Österreich beträgt 0,50 ($10/20$); die relative Häufigkeit von Versuchspersonen aus Deutschland beträgt 0,40 ($8/20$) und die relative Häufigkeit von Versuchspersonen aus der Schweiz beträgt 0,10 ($2/20$). Die Summe der relativen Anteile beträgt immer 1. Werden die relativen Häufigkeiten mit 100 multipliziert, so erhält man die **prozentualen Häufigkeiten**. Die prozentuale Häufigkeit der Versuchspersonen aus Österreich liegt bei 50 %, die prozentuale Häufigkeit der Versuchspersonen aus Deutschland liegt bei 40 % und die prozentuale Häufigkeit der Versuchspersonen aus der Schweiz liegt bei 10 % (Hussy et al., 2013). Wenn man Häufigkeiten berichtet, ist es wichtig, dass man explizit angibt, ob es sich um absolute oder relative Häufigkeiten handelt, damit die Ergebnisse auch korrekt interpretiert werden (vgl. Abbildung 3.15).



Abbildung 3.15: Die Fehlinterpretation von Ergebnissen beruht oft darauf, dass absolute und relative Häufigkeiten vermischt werden, oder unklar ist, welche Art der Häufigkeit berichtet wurde; aus Huber (2019, S. 54)

KAPITEL 3. PSYCHOLOGISCHE FORSCHUNG UND METHODENLEHRE

Möchte man die Häufigkeiten von kontinuierlichen Variablen, welche theoretisch unendlich viele Ausprägungen annehmen können, angeben, bietet es sich an, dass man Intervalle bildet und alle Ausprägungen, die in ein Intervall fallen, gruppiert. Häufig anzutreffen ist diese Vorgehensweise bei der Variable „Alter“. Ein Beispiel dazu finden Sie in Tabelle 3.3. Die Gruppierung zu Kategorien erfolgt dabei im Grunde willkürlich, es sollte aber auf einige Kriterien geachtet werden. Dazu gehört beispielsweise, dass die Intervalle mit Ausnahme der Randkategorien möglichst gleich groß sind und die Enge/Breite der Intervalle und somit auch die Anzahl der Kategorien von der Größe der Stichprobe und der Variationsbreite der Messwerte abhängig gemacht wird (Hussy et al., 2013).

Möchte man Häufigkeitsverteilungen veranschaulichen, so eignen sich dazu **Histogramme**. Bei Histogrammen sind auf der x-Achse die Ausprägungen der Variable und auf der y-Achse die jeweiligen Häufigkeiten aufgetragen. Es können entweder die absoluten Häufigkeiten oder die relativen Anteile der Ausprägungen angegeben werden. In Abbildung 3.16 sehen Sie das der Tabelle 3.3 entsprechende Histogramm mit den absoluten Häufigkeiten.

Tabelle 3.3: Absolute, relative und prozentuale Häufigkeiten der Variable „Alter“

Alter	Absolute Häufigkeit	Relative Häufigkeit	Prozentuale Häufigkeit
18–24 Jahre	16	0,100	10,0 %
25–34 Jahre	24	0,150	15,0 %
35–44 Jahre	20	0,125	12,5 %
45–54 Jahre	48	0,300	30,0 %
55–64 Jahre	36	0,225	22,5 %
65 und älter	16	0,100	10,0 %




Abbildung 3.16: Histogramm zu den Daten aus Tabelle 3.3

3.5.2 Maße der zentralen Tendenz

Neben der Möglichkeit die Häufigkeitsverteilung anzugeben, kann es auch einen beschreibenden Charakter haben, wenn man einen repräsentativen Wert der Stichprobe angibt. Ein solcher Wert wird auch als **Maß der zentralen Tendenz** bezeichnet. Die Angabe von repräsentativen Werten ist vor allem dann üblich, wenn zwei oder mehr Gruppen hinsichtlich des Merkmals miteinander verglichen werden. Gebräuchliche Maße der zentralen Tendenz sind der Modalwert, der Median und das arithmetische Mittel.

Der **Modalwert** ist der Wert mit der größten absoluten Häufigkeit. Die Angabe des Modalwerts ist insbesondere bei Variablen mit einem nominalen Skalenniveau aussagekräftig. Bei Variablen mit einem höheren Skalenniveau kann er zwar bestimmt werden, meist ist dieser Wert dann aber nicht sehr aussagekräftig und es wird eher der Median oder das arithmetische Mittel berechnet. Bezogen auf das Beispiel zur Häufigkeitsverteilung der Nationalität wäre der Modalwert Österreich, da diese Nationalität am häufigsten angegeben wurde (Hussy et al., 2013).

Der **Median** ist jener Wert, der dann, wenn man alle Messwerte in eine aufsteigende Reihenfolge bringt, genau in der Mitte liegt bzw. die Verteilung halbiert. Der Median kann nicht für Variablen mit nominalen Skalenniveau, sondern erst ab einem ordinalen Skalenniveau bestimmt werden. Bei einer geraden Anzahl von Werten kann es passieren, dass der Median nicht genau bestimmt werden kann, weil dieser genau zwischen zwei verschiedenen Werten liegt. In diesem Fall wird in der Regel der Mittelwert (das arithmetische Mittel) der beiden mittleren Werte bestimmt, welcher dann als Median gilt. Gegenüber dem arithmetischen Mittel hat der Median den Vorteil, dass er robust gegenüber sogenannten Ausreißern ist. Als Ausreißer versteht man in der Statistik Werte, die nicht den Erwartungen entsprechen, weil sie weit von den anderen Werten entfernt liegen (Gerrig et al., 2018; Bortz & Schuster, 2010).

Das **arithmetische Mittel** ist der Wert, an den meist gedacht wird, wenn vom *Durchschnitt* die Rede ist und auch jener, welcher am häufigsten verwendet wird. Berechnet wird das arithmetische Mittel, indem alle einzelnen Werte aufsummiert und durch die Gesamtanzahl der Werte dividiert werden (siehe Formel 3.1).

$$M = \frac{\sum_{i=1}^N x_i}{N} \quad (3.1)$$

In der Formel steht M für das arithmetische Mittel, N für die Gesamtanzahl der Werte und x_i für die einzelnen Werte, wobei i einen Laufindex darstellt, der alle Werte von $i = 1$ bis $i = N$ durchläuft. Es werden also alle Werte x_i , vom ersten bis zum N -ten Wert, aufsummiert und schließlich durch die Gesamtanzahl N dividiert. Zu beachten ist dabei, dass die Berechnung mindestens Daten auf Intervallskalenniveau voraussetzt (Gerrig et al., 2018). Rechenbeispiel 3.1 zeigt die Bestimmung der verschiedenen Maße an einem Beispiel.

Rechenbeispiel 3.1: Maße der zentralen Tendenz

Im Rahmen einer Studie wurden die Reaktionszeiten von fünf Versuchspersonen aufgezeichnet. Die Reaktionszeiten haben ein Verhältnisskalenniveau, daher können sowohl der Modalwert, der Median als auch das arithmetische Mittel bestimmt werden. Die aufgezeichneten Reaktionszeiten in Millisekunden in bereits aufsteigender Reihenfolge sind: [200, 200, 230, 280, 290].

Es gibt nur einen Wert, der häufiger als einmal auftritt und zwar der Wert 200. Der Wert 200 tritt zweimal auf und ist daher der **Modalwert**.

Da es sich um eine ungerade Anzahl an Werten handelt, kann der **Median** leicht als der Wert in der Mitte, also der dritte von fünf Werten, identifiziert werden. Der Median beträgt 230 Millisekunden.

Für die Bestimmung des **arithmetischen Mittels** werden die Werte in Formel 3.1 eingesetzt. Das **arithmetische Mittel** beträgt 240 Millisekunden.

$$M = \frac{200 + 200 + 230 + 280 + 290}{5} = 240$$

Es wurde bereits angesprochen, dass der Median gegenüber dem arithmetischen Mittel den Vorteil hat, dass er robust gegen Ausreißer ist. Diese Tatsache soll an dieser Stelle noch veranschaulicht werden: Angenommen, Sie erheben in zwei Gruppen die Anzahl der Stunden, die Personen in einer Woche mit Sport verbringen. Unter den Versuchspersonen befindet sich in einer Gruppe (Gruppe 2) auch eine Leistungssportlerin, die deutlich mehr Sport macht, als die anderen Versuchspersonen: Gruppe 1 = [1, 2, 2, 5, 5], Gruppe 2 = [1, 2, 2, 5, 20]. In beiden Fällen ergibt sich ein Median von 2. Das arithmetische Mittel der ersten Gruppe beträgt $M_1 = 3$, das der zweiten Gruppe $M_2 = 6$. Diese Verdopplung der durchschnittlichen Sportdauer, gemessen durch das arithmetische Mittel wurde durch eine einzelne Person (einen Ausreißer) verursacht.

3.5.3 Maße der Streuung

Streuungsmaße geben an, wie stark die verschiedenen Werte der Stichprobe sich voneinander unterscheiden, also wie stark die Werte „streu“en. Die Angabe eines solchen Maßes zusätzlich zu einem Maß der zentralen Tendenz für die Beschreibung der Stichprobe ist insofern wichtig, als dass der Mittelwert die Verteilung umso weniger repräsentiert, je mehr Streuung vorliegt. Maße der Streuung bieten zusätzliche Informationen über die Stichprobe. Haben zwei Stichproben ähnliche Mittelwerte, bedeutet dies nicht, dass sich die Stichproben ähnlich sind (Bortz & Schuster, 2010).

Für Daten mit Nominalskalenniveau kann kein Maß der Streuung berichtet werden, weil sich die einzelnen Ausprägungen in keiner kleiner-größer-Beziehung zueinander befinden. Für Daten mit mindestens Ordinalskalenniveau kann der **Interquartilsabstand** (IQA) als Maß der Streuung berechnet werden. Ist die Stichprobe der Größe nach sortiert, dann gibt der Interquartilsabstand an, wie breit der Bereich ist, in dem die mittleren 50 % der Verteilung liegen (siehe Abbildung 3.17).

KAPITEL 3. PSYCHOLOGISCHE FORSCHUNG UND METHODENLEHRE

Um den Interquartilsabstand zu bestimmen, werden zunächst das untere Quartil $Q1$ und das obere Quartil $Q3$ bestimmt und anschließend die Differenz $Q3 - Q1$ gebildet. Vereinfacht gesagt, ist das untere Quartil $Q1$ der Median der Werte, welche unter dem Median ($Q2$) liegen und das obere Quartil $Q3$ der Median der Werte, welche über dem Median ($Q2$) liegen. Im Falle einer geraden Stichprobenanzahl kann die Stichprobe in zwei exakt




Abbildung 3.17: Innerhalb der Quartile $Q1$ und $Q3$ liegen 50% der Daten

gleich große Teile aufgeteilt werden und es befinden sich $N/2$ Werte unterhalb und $N/2$ überhalb des Medians ($Q2$). Im Falle einer ungeraden Stichprobenanzahl wird der Median zu beiden Hälften mitgezählt (Bortz & Schuster, 2010).

Das wohl bekannteste Maß der Streuung ist aber die **Varianz**. Die Varianz ist die Summe der quadrierten Abweichungen aller Werte vom arithmetischen Mittelwert, dividiert durch die Gesamtanzahl der Werte (siehe Formel 3.2). Dafür wird für alle Werte x_i die Differenz zum arithmetischen Mittelwert M bestimmt, aufsummiert und schließlich durch die Gesamtanzahl N dividiert^D.

$$Var = \frac{\sum_{i=1}^N (x_i - M)^2}{N} \quad (3.2)$$

Eng verwandt mit der Varianz ist die **Standardabweichung**. Die Standardabweichung ist die Wurzel der Varianz. In Formel 3.3 zur Berechnung der Standardabweichung ist zu sehen, dass sich diese Formel zur Formel zur Berechnung der Varianz nur durch die Wurzel unterscheidet, daher gilt $SD = \sqrt{Var}$. Um die Varianz und die Standardabweichung berechnen zu können, müssen die Daten mindestens Intervallskalenniveau aufweisen (Bortz & Schuster, 2010). In Rechenbeispiel 3.2 finden Sie die Berechnung der Streuungsmaße.

$$SD = \sqrt{\frac{\sum_{i=1}^N (x_i - M)^2}{N}} \quad (3.3)$$

^DFalls Sie bereits die korrigierte Formel mit der Division durch $N - 1$ (Bessel-Korrektur) kennen: Wir beziehen uns in diesem Lernskript ausschließlich auf die unkorrigierte Formel, da lediglich die Varianz der Stichprobe berechnet wird und keine Schätzung der Populationsvarianz erfolgt.

KAPITEL 3. PSYCHOLOGISCHE FORSCHUNG UND METHODENLEHRE

Rechenbeispiel 3.2: Streuungsmaße

Für die Reaktionszeiten in 3.1 sollen nun auch die Streuungsmaße berechnet werden: [200, 200, 230, 280, 290]

Für die Bestimmung der **Varianz** muss die Summe der quadratischen Abweichungen vom arithmetischen Mittel gebildet werden, die dann durch die Stichprobengröße dividiert wird. Das arithmetische Mittel ist bereits bekannt und beträgt 240 Millisekunden. Die resultierende Varianz beträgt 1480 Millisekunden.

$$Var = \frac{(200 - 240)^2 + (200 - 240)^2 + (230 - 240)^2 + (280 - 240)^2 + (290 - 240)^2}{5} = 1480$$

Für die Bestimmung der **Standardabweichung** wird die Wurzel der Varianz gebildet. Die Standardabweichung beträgt etwa 38,47 Millisekunden.

$$SD = \sqrt{1480} \approx 38,47$$

Für die Bestimmung des **IQA** muss zunächst die Größe der Stichprobe bestimmt werden. Im Beispiel liegt eine ungerade Stichprobenanzahl vor, daher wird der Median in beiden Hälften mitberücksichtigt. Anschließend wird der mittlere Wert der unteren drei Werte und der mittlere Wert der oberen drei Werte bestimmt: $Q1 = 200$, $Q3 = 280$. Anschließend wird die Differenz gebildet. Der IQA beträgt 80 Millisekunden.

$$IQA = Q3 - Q1 = 280 - 200 = 80$$

3.5.4 Zusammenhangsmaße

Zusammenhangsmaße beschreiben Zusammenhänge zwischen zwei oder mehreren Variablen. Eine grafische Möglichkeit zur Veranschaulichung des Zusammenhangs zwischen zwei Variablen ist das **Streudiagramm**, bei dem auf einer Achse die Ausprägungen der einen Variable und auf der anderen Achse die Ausprägungen der anderen Variable aufgetragen werden. Ein solches Streudiagramm, basierend auf den Daten in Tabelle 3.4, ist in Abbildung 3.18 abgebildet, in dem ein möglicher Zusammenhang zwischen der Lerndauer in Stunden für einen Geografietest und die erreichten Punkte im Geografietest veranschaulicht wird, wobei die Daten aus Gründen der Übersichtlichkeit bereits nach der Lerndauer sortiert sind. Jeder Punkt des Streudiagramms repräsentiert eine Versuchseinheit – in der Psychologie in der Regel Personen.

Tabelle 3.4: Beispieldaten für den Zusammenhang von Lerndauer und Punkten im Geografietest

	VP1	VP2	VP3	VP4	VP5	VP6	VP7	VP8	VP9	VP10
Lerndauer	0	1	1,5	2,5	3	4,5	6	6,5	7	8
Punkte	1	8	6	11	13	15	13	17	19	17




Abbildung 3.18: Ein Streudiagramm, das den Zusammenhang zwischen der Lerndauer und dem Ergebnis im Geografietest veranschaulicht

Ein Streudiagramm kann einen ersten Eindruck über den Zusammenhang von zwei Variablen vermitteln. Möchte man mehr Informationen über den Zusammenhang von zwei Variablen erhalten, kann bei mindestens intervallskalierten Daten der **Korrelationskoeffizient**, auch Produkt-Moment-Korrelation genannt, berechnet werden, der den Grad des linearen Zusammenhangs quantifiziert. Von einem linearen Zusammenhang spricht man dann, wenn sich mit zunehmender Ausprägung der einen Variable auch die andere Variable in eine Richtung (zunehmend oder abnehmend, jedoch nicht abwechselnd) verändert. Der Korrelationskoeffizient ist nicht dafür geeignet, nichtlineare, beispielsweise quadratische Zusammenhänge, welche im Streudiagramm einen U-förmigen Verlauf annehmen würden, zu quantifizieren. Der Korrelationskoeffizient wird in der Regel mit dem Buchstaben r bezeichnet. Der Korrelationskoeffizient ist das standardisierte Maß der Kovarianz. Zur Berechnung der Kovarianz wird für jede Versuchseinheit der Abstand der Ausprägung der einen Variable zum Mittelwert dieser Variable mit dem Abstand der Ausprägung der anderen Variable zu deren Mittelwert multipliziert, über alle Versuchseinheiten aufsummiert und durch die Anzahl der Versuchseinheiten dividiert (Formel 3.4):

$$Cov(x, y) = \frac{\sum_{i=1}^N (x_i - M_x) \cdot (y_i - M_y)}{N} \quad (3.4)$$

Eine hohe Kovarianz liegt folglich dann vor, wenn entweder positive Abstände häufig mit positiven Abständen und negative Abstände häufig mit negativen Abständen multipliziert werden (ergibt eine positive Kovarianz) oder wenn positive Abstände häufig mit negativen Abständen multipliziert werden (ergibt eine nega-

KAPITEL 3. PSYCHOLOGISCHE FORSCHUNG UND METHODENLEHRE

tive Kovarianz). Liegt hingegen eine Mischung vor, heben sich die negativen und positiven Werte auf und die Kovarianz liegt in der Nähe von Null. Die Kovarianz hat allerdings den Nachteil, dass sie von den Einheiten der beiden Variablen abhängt. Das bedeutet, dass die Messung des Gewichts in Gramm zu einer anderen Kovarianz führt als die Messung des Gewichts in Kilogramm. Um das Ausmaß der Streuung unabhängig von den Einheiten ermitteln zu können, wird die Kovarianz durch das Produkt der Standardabweichungen der beiden Variablen dividiert. Das resultierende Maß ist der Korrelationskoeffizient r (Formel 3.5):

$$r = \frac{Cov(x, y)}{SD(x) \cdot SD(y)} \quad (3.5)$$

Rechenbeispiel 3.3: Korrelationskoeffizient

In diesem Beispiel werden die Kovarianz und der Korrelationskoeffizient berechnet, wobei die Mittelwerte $M_x = 4$ und $M_y = 12$ und die Standardabweichungen $SD_x \approx 2,64$ und $SD_y \approx 5,33$ bereits bekannt sind. Zur Ermittlung der Kovarianz werden zunächst die Abstände der Werte der Versuchseinheiten zu den jeweiligen Variablenmittelwerten bestimmt. Anschließend werden die Abstände miteinander multipliziert und über alle Versuchseinheiten aufsummiert. Abschließend wird durch die Anzahl der Versuchseinheiten dividiert. Die einzelnen Berechnungsschritte sind in der Tabelle dargestellt.

	x_i	y_i	$(x_i - M_x)$	$(y_i - M_y)$	$(x_i - M_x) \cdot (y_i - M_y)$
VP1	0	1	-4	-11	44
VP2	1	8	-3	-4	12
VP3	1,5	6	-2,5	-6	15
VP4	2,5	11	-1,5	-1	1,5
VP5	3	13	-1	1	-1
VP6	4,5	15	0,5	3	1,5
VP7	6	13	2	1	2
VP8	6,5	17	2,5	5	12,5
VP9	7	19	3	7	21
VP10	8	17	4	5	20
Σ					128,5

$$Cov(x, y) = \frac{\sum_{i=1}^N (x_i - M_x) \cdot (y_i - M_y)}{N} = \frac{128,5}{10} = 12,85$$

Aus der Kovariation kann durch die Division des Produktes der beiden Standardabweichungen der Korrelationskoeffizient berechnet werden. Diese Berechnung ergibt $r = 0,91$:

$$r = \frac{Cov(x, y)}{SD_x \cdot SD_y} = \frac{12,85}{2,64 \cdot 5,33} \approx 0,91$$

Der Korrelationskoeffizient ist unabhängig von den Einheiten der beiden Variablen und kann einen Wert zwischen -1 und 1 annehmen. Nimmt der Koeffizient den Wert 0 an, liegt kein linearer Zusammenhang zwischen den beiden Variablen vor. Nimmt der Koeffizient einen Wert zwischen -1 und 0 an, liegt eine **negative Korrelation** vor. Das bedeutet, eine Zunahme der einen Variable ist mit einer Abnahme der anderen Variable assoziiert, wobei -1 einer perfekten negativen Kor-

KAPITEL 3. PSYCHOLOGISCHE FORSCHUNG UND METHODENLEHRE

relation entspricht. Je negativer der Koeffizient, desto höher der negative Zusammenhang der beiden Variablen. Nimmt der Koeffizient einen Wert zwischen 0 und 1 an, liegt eine **positive Korrelation** vor, bei der die Zunahme der einen Variable mit einer Zunahme der anderen Variable assoziiert ist. Ein Korrelationskoeffizient von 1 entspricht einer perfekten positiven Korrelation. Sie finden in Abbildung 3.19 Streudiagramme, welche jeweils den angegebenen Korrelationen entsprechen. Je weiter r von 0 entfernt liegt, desto höher ist die Korrelation und desto leichter lässt sich auch optisch ein Trend in den Daten erkennen (Bortz & Schuster, 2010). Eine weitere Möglichkeit zur Einschätzung der Höhe der Korrelation ist es, die Datenpunkte „einzukreisen“. Je mehr die Form einem Kreis ähnelt, desto geringer ist die Korrelation. Je mehr die Form einer Ellipse ähnelt (und je „schmäler“ diese ist), desto höher ist die Korrelation. Bei einer perfekten Korrelation liegen die Datenpunkte auf einer Linie. Je höher die Korrelation ist, desto genauere Vorhersagen können auf Basis einer Variable über die andere Variable getroffen werden.




Abbildung 3.19: Bei positiven Korrelationen sind überdurchschnittliche Werte der Variable x mit überdurchschnittlichen Werten der Variable y und unterdurchschnittliche Werte der Variable x mit unterdurchschnittlichen Werten der Variable y assoziiert (a–c). Bei einer negativen Korrelation sind unterdurchschnittliche Werte der Variable x mit überdurchschnittlichen Werten der Variable y und überdurchschnittliche Werte der Variable x mit unterdurchschnittlichen Werten der Variable y assoziiert (d–f).